

机器学习常用术语目录

机器学习常用术语词汇表	2
监督学习	2
无监督学习	2
半监督学习	2
线性回归	3
神经元	3
链式法则	3
前向传播	3
反向传播	3
下采样	3
上采样	3
过拟合	3
欠拟合	4
梯度下降	4
梯度上升	4
步长	4
学习率	4
权重	4
偏置	4
注意力机制	5
编码器	5
解码器	5
梯度爆炸	5
梯度消失	5
损失函数	5
输入层	5
输出层	6
隐藏层	6
卷积层	6
激活层	6
激活函数	6
池化层	6
全连接层	6
神经网络	7
前馈神经网络	7
卷积神经网络	7
循环神经网络	7
长短时记忆神经网络	7
残差	7

残差网络	8
感知机	8
多层感知机	8
Transformer	8
Backbone	8
Head	10
Neck	10
Baseline	10
SOTA	10
CheckPoints	10
感受野	11
编码-解码	11



机器学习常用术语词汇表

监督学习

所谓监督学习，就是先利用**有标签**的训练数据学习得到一个模型，然后使用这个模型对新样本进行预测。在本质上，监督学习的目标在于，构建一个由输入到输出的映射，该映射用模型来表示。

无监督学习

与监督学习相反，无监督学习的数据是**没有标签**的，我们把数据给机器，并让它试着从这些数据中找到某种结构。无监督学习使我们能够在不知道结果应该是什么的情况下处理问题。我们可以从不一定知道变量影响的数据中导出结构。简单来说，无监督学习中的数据没有任何标签，拿到数据集，我们并不知道要拿它来做什么，也不知道每个数据点究竟是什么，而只是被告知这里有一个数据集，能否在其中找到某种有意义的结构。

半监督学习

半监督学习是一种介于监督学习和无监督学习之间的学习。在现实生活中，无标签的数据易于获取，而有标签的数据收集起来通常很困难，标注也耗时和耗力。在这种情况下，半监督学习（**Semi-Supervised Learning**）更适用于现实世界中的应用。半监督学习（这里仅针对半监督分类），就是要利用**大量的无标签样本**和**少量带有标签的样本**来训练分类器，解决有标签样本不足的难题。

线性回归

利用回归函数对一个或多个自变量和因变量之间关系进行建模的一种分析方法。只有一个自变量的情况称为单变量回归，多于一个自变量的情况叫多元回归。

神经元

神经元是构成神经网络的基本单元，其主要是模拟生物神经元

的结构和特性，接受一组输入信号并产出输出。通过神经元，人工神经网络可以以数学模型模拟人脑神经元活动，继而进行高效的计算以及其他处理。

链式法则

链式法则是微积分中的求导法则，用于求一个复合函数的导数，是在微积分的求导运算中一种常用的方法。复合函数的导数将是构成复合这有限个函数在相应点的导数的乘积，就像锁链一样一环套一环，故称链式法则。

前向传播

简单理解就是将上一层的输出作为下一层的输入，并计算下一层的输出，一直到运算到输出层为止。

反向传播

反向传播算法定义为在已知分类的情况下，为给定的输入模式训练某些给定的前馈神经网络的算法。反向传播是在链式法则的基础上实现的。

下采样

下采样就是图像的缩小的过程。把底层图生成特征图的过程。

上采样

简单的理解就是把图片进行放大了，把特征图反推出原图的过程。

过拟合

一个假设在训练集上能够获得比其他假设更好的拟合，但是在测试集上却不能更好的拟合数据，此时就认为模型出现过拟合现象，即为：模型过于复杂。简单来说，训练集表现的比测试集好。产生过拟合的原因：如训练数据太少，选样方法错误，样本标签错误等等。

欠拟合

一个假设在训练集上不能获得更好的拟合，并且在测试集上也不能很好的拟合数据，此时人文模型出现欠拟合现象，即为：

模型过于简单。简单来说，测试集和训练集表现的都不好。欠拟合产生的原因：1、使用的模型复杂度过低 2、使用的特征量过少。

梯度下降

度下降法就是沿着梯度下降的方向求解极小值。

梯度上升

沿着梯度上升的方向可以求得最大值，这种方法叫梯度上升。

步长

每一步梯度下降时向目标方向前行的长度。

学习率

将输出误差反向传播给网络参数，以此来拟合样本的输出，本质上是最优化的一个过程，逐步趋向于最优解，但是每一次更新参数利用多少误差，就需要通过一个参数来确定，这个参数就是学习率，也称步长（上面的步长用的是最优化中的概念，在深度学习中，两者表示同一个东西）。

权重

权重是一个相对的概念，是针对某一指标而言。某一指标的权重是指该指标在整体评价中的相对重要程度。

偏置

偏置单元 (bias unit)，在有些资料里也称为偏置项 (bias term) 或者截距项 (intercept term)，它其实就是函数的截距，与线性方程 $y=wx+b$ 中的 b 的意义是一致的。在 $y=wx+b$ 中， b 表示函数在 y 轴上的截距，控制着函数偏离原点的距离，其实在神经网络中的偏置单元也是类似的作用。偏置可以用来避免输出为零的情况，并且能够加速某些操作，这让解决某个问题所需要的神经元数量也有所减少。

注意力机制

注意力机制 (Attention Mechanism) 是人们在机器学习模型中嵌入的一种特殊结构，用来自动学习和计算输入数据对输出数据的贡献大小。它实际上就是想将人的感知方式、注意力的行为

应用在机器上，让机器学会去感知数据中的重要和不重要的部分。

编码器

编码器（**encoder**）用来分析输入序列。

解码器

解码器（**decoder**）用来生成输出序列。它从编码器获取特征向量，并输出与实际输入或预期输出最近似的结果。

梯度爆炸

误差梯度在网络训练时被用来得到网络参数更新的方向和幅度，进而在正确的方向上以合适的幅度更新网络参数。在深层网络或递归神经网络中，误差梯度在更新中累积得到一个非常大的梯度，这样的梯度会大幅度更新网络参数，进而导致网络不稳定。在极端情况下，权重的值变得特别大，以至于结果会溢出（NaN 值，无穷与非数值）。当梯度爆炸发生时，网络层之间反复乘以大于 1.0 的梯度值使得梯度值成倍增长。

梯度消失

梯度下降公式里，导数部分很小很小，可能接近于 0，导致训练极度缓慢（权重变化很小），这种现象就叫梯度消失，一般是由训练层的激活函数导致的。

损失函数

在训练模型中，用来衡量预测值和真实值之间的误差，就叫损失函数，数值越小表示的误差越小。

输入层

输入层主要获取输入的信息。在神经网络中，通过输入层激活信号，再通过隐藏层提取特征，不同隐藏层神经单元对应不同输入层的神经单元权重和自身偏置均可能不同，输入层兴奋传递到隐藏层兴奋，最后输出层根据不同的隐藏层权重和自身偏置输出结果。

输出层	输出层负责对接隐藏层并输出最后的结果。
隐藏层	除输入层、输出层以外的层叫做隐藏层，隐藏层是其他几个功能层的总称。主要进行特征提取，调整权重让隐藏层的神经单元对某种模式形成反应。
卷积层	通过卷积操作对输入图像进行降维和特征抽取。
激活层	进行非线性整合（为什么要加入非线性因素，因为线性模型表达不够）。
激活函数	所谓激活函数（ Activation Function ），就是在人工神经网络的神经元上运行的函数，负责将神经元的输入映射到输出端。一般神经网络是线性的，引入激活函数，是在神经网络中引入非线性，强化网络的学习能力。所以激活函数的最大特点就是非线性。常见的激活函数有 <code>sigmoid</code> 、 <code>tanh</code> 、 <code>softsign</code> 、 <code>ReLU</code> 、 <code>softplus</code> 、 <code>logistics</code> 等等。
池化层	对输入的特征图进行压缩，一方面使特征图变小，简化网络计算复杂度；一方面进行特征压缩，提取主要特征。通常在卷积层之后会得到维度很大的特征，将特征切成几个区域，取其最大值或平均值，得到新的、维度较小的特征。
全连接层	全连接层的每一个节点都与上一层所有的节点相连，从而把前边提取到的特征综合起来。将图像展开，进行分类操作。
神经网络	是一种模仿生物神经网络的结构和功能的数学模型或计算模型。神经网络由大量的人工神经元联结进行计算。大多数情况下人工神经网络能在外界信息的基础上改变内部结构，是一种自适应系统。现代神经网络是一种非线性统计性数据建模工具，常用来对输入和输出间复杂的关系进行建模，或用来探索数据

的模式。

前馈神经网络

各神经元分别属于不同的层，层内无连接。而是层与层之间的连接。整个网络无反馈，信号从输入层向输出层单向传播。

卷积神经网络

卷积神经网络（VGG）是含有卷积层的神经网络。

循环神经网络

循环神经网络（RNN）的来源是为了刻画一个序列当前的输出与之前信息的关系。从网络结构上，循环神经网络会记忆之前的信息，并利用之前的信息影响后面结点的输出。即：循环神经网络的隐藏层之间的结点是有连接的，隐藏层的输入不仅包括输入层的输出，还包括上一时刻隐藏层的输出。

长短时记忆神经网络

长短时记忆网络（LSTM）是一种能够捕捉长时依赖的特殊循环神经网络。LSTM 相对于基础的 RNN 网络来说，记忆能力更强，更擅长处理较长的序列信号数据。LSTM 有三个门，输入门、遗忘门。LSTM 网络能通过一种被称为门的结构对细胞状态进行删除或者添加信息。门能够有选择性的决定让哪些信息通过。

残差

残差在数理统计中是指实际观察值与估计值（拟合值）之间的差。“残差”蕴含了有关模型基本假设的重要信息。如果回归模型正确的话，我们可以将残差看作误差的观测值。

残差网络

如果神经网络层数越多，网络越深，源于梯度消失和梯度爆炸的影响，整个模型难以训练成功。解决的方法之一是人为地让神经网络某些层跳过下一层神经元的连接，隔层相连，弱化每层之间的强联系。这种神经网络被称为 Residual Networks(ResNets)。

感知机

感知机是一种二类分类的线性分类模型，其输入为实例的特征向量，输出为实例的类别，+1 代表正类，-1 代表负类。感知机属于判别模型，它的目标是要将输入实例通过分离超平面将正负二类分离。

多层感知机

多层感知机（MLP, Multilayer Perceptron）也叫人工神经网络（ANN, Artificial Neural Network），除了输入输出层，它中间可以有多个隐层，最简单的 MLP 只含一个隐层，即三层的结构。多层感知机（MLP）是几个完全相邻连接的感知机层的实现，形成一个简单的前馈神经网络。这种多层感知机具有单感知机不具备的非线性激活功能的优势。

Transformer

Transformer 是 Google 的研究者于 2017 年在《Attention Is All You Need》一文中提出的一种用于 seq2seq 任务的模型，它没有 RNN 的循环结构或 CNN 的卷积结构，在机器翻译等任务中取得了一定提升。目前也在 CV 领域中有着广泛地应用。

Backbone

主干（骨干）网络，一般是指提取特征的网络，其作用就是提取图片中的信息，供后面的网络使用。此外，被称作 backbone 的网络通常都是已在大型数据集(例如 ImageNet、COCO 等)上完成了预训练，拥有预训练参数的卷积神经网络。经常使用的主干网络有 ResNet、VGG 等，而不是我们自己设计的网络，因为这些网络已经被充分证明在分类等问题上具有很强的特征提取能力。在使用这些网络作为 backbone 的时候，都是直接加载官方已经训练好的模型参数，后面接着我们自己的网络。通常会同时训练网络的这两个部分，这是因为加载的 backbone 模型已经具有提取特征的能力了，而在我们的训练过程中，只需要对其进行微调，使得其更适合于我们自己的任务。

Head

一般是指具有获取网络输出内容能力的网络（也称作检测头），通过利用之前提取的特征，预测目标的种类和位置。

Neck

一般是指介于 **backbone** 和 **head** 之间用于收集不同阶段中特征图的网络层，作用是为了更好的利用 **backbone** 提取的特征。

注意:基于深度学习的目标检测模型的一般结构是：输入->主干->脖子->头->输出。主干网络提取特征，脖子提取一些更复杂的特征，然后头部计算预测输出。

Baseline

baseline 有一个自带的含义就是“性能起点”。这里还需要指出其另一个应用语境，就是在算法优化过程中，一般 **version1.0** 是作为 **baseline** 的，即这是你的算法能达到的一个基本性能，在算法继续优化和调参数的过程中，你的目标是比这个性能更好，因此需要在这个 **baseline** 的基础上往上跳。**baseline** 这个名词在很多的竞赛中很常见，一般都是在此基础上进行“魔改”，以它为标准，来判断改进的好坏。**baseline** 一般是自己算法优化和调参过程中自己和自己比较中的基础起点，目标是越来越好，当性能超过 **benchmark** 时，可以发表了。当然有些时候文章中的 **baseline** 指代其他论文提出的方法，所以阅读论文的时候要结合语境，灵活理解。

SOTA

SOTA(state-of-the-art)算法性能在当前属于最佳性能。

CheckPoints

对于耗时处理，应用检查点机制是一种故障容错技术。它是一种在系统出错情况下快照系统状态的方法。如果有问题，不会全部丢失。检查点可以直接使用，或者作为新程序的起点，在他中断的地方加载数据。当训练深度学习模型，检查点能捕获模型权重。这些权重用于做预测，或者用于继续训练的基础。

感受野

感受野是指在卷积过程中卷积核关注的区域，故浅层卷积核关注的是细节特征，例如颜色、角点、直线曲线等；高层的卷积核关注的是全局特征，例如汽车、飞机、老虎等。

编码-解码

在深度学习中，自动编码器是一种无监督的神经网络模型，它可以学习到输入数据的隐含特征，这称为编码(coding)，同时用学习到的新特征可以重构出原始输入数据，称之为解码(decoding)。

