

基于改进卷积神经网络的寒地水稻常见叶部病害识别

崔佳鹏¹, 徐宏扬¹, 付亚萍²

(1. 黑龙江省农业机械工程科学研究院 绥化分院, 黑龙江 绥化 152054; 2. 黑龙江省农业科学院 大豆研究所, 哈尔滨 150086)

摘 要: 传统卷积神经网络对于水稻病害识别存在局限性, 特别是在寒地水稻病斑位置识别方面。为此, 提出了一种改进型轻量级深度学习网络模型, 建立了一个包含 5 种常见寒地水稻叶部病害图像的数据集, 并构建了病害分类和病斑目标检测网络模型; 将图像分类网络嵌入 YOLOv3 目标检测网络中, 并对模型的特征提取部分进行了优化, 采用转置卷积和空洞卷积进行上采样和下采样; 最后, 对比了改进后的 YOLOv3 模型与传统的卷积神经网络模型。试验结果表明, 病害分类模型在各项指标上均表现出色, 平均召回率、平均精度、平均 F1-Score 和总体准确率分别为 93.64%、93.74%、93.77% 和 93.64%。改进后的 YOLOv3 模型在病斑检测方面也表现出色, 平均检测精度 (mAP) 达到 89.79%, 检测率 (DR) 达到 94.94%, 检测速度达到 64.9 f/s, 综合性能明显优于传统的 YOLOv3 算法, 为水稻病害的准确快速识别提供了新途径, 对水稻病害的监测和防治具有重要意义。

关键词: 寒地水稻病斑识别; 卷积神经网络; 目标检测; 图像分类

中图分类号: S225.93

文献标识码: A

文章编号: 1003-188X(2025)10-0233-10

DOI: 10.13427/j.issn.1003-188X.2025.10.030

0 引 言

水稻是我国重要的粮食作物之一, 占据了全国粮食产量的 30%。然而, 在水稻生长过程中, 面临着多种不同的病害威胁。近年来, 由于全球温室效应、水稻种植方式改变、品种选择和农药使用不合理等多种原因, 水稻病害的发生面积不断扩大, 病害种类也日益增多, 且危害程度严重。每年由于水稻病害而造成的损失相当巨大, 直接影响了水稻产量, 进一步对我国粮食储备构成了威胁。因此, 对水稻病害进行监测和有效防治具有极其重要的意义^[1], 不仅关系到水稻的健康生产, 而且关系到我国国民经济的发展。

目前, 水稻病害的识别方法主要分为 3 类: 人工检测、半自动检测和自动检测^[2]。人工检测是依赖人工视觉来观察水稻病斑, 然后根据专业知识和经验来主观判断病害的种类; 半自动检测方法需要人工手动提取水稻病斑的颜色、纹理、形态等底层特征, 然后利用机器学习算法 (如支持向量机和随机森林), 对病害进行分类; 自动检测方法采用深度学习技术, 通过有监督

或半监督学习, 利用大量水稻病斑数据进行驱动, 自动提取多层特征, 从而实现对水稻病害的识别。

近年来, 随着计算机技术的进步和农业信息化的推广, 许多国内外学者积极探索利用计算机图像处理和模式识别技术来实现自动识别和诊断作物病害^[3]。Sethy 等^[4]探讨了深度卷积神经网络 (CNN) 在水稻病害识别方面的进展, 以实现高效的病害检测, 研究中使用 5 932 张田间图像, 涵盖了水稻白叶枯病、稻瘟病、褐斑病和东格鲁病等 4 种病害。此外, 研究还对 11 个 CNN 模型在迁移学习和深度特征结合支持向量机 (SVM) 方法下的性能进行了评估。实验结果表明: 相对于仅使用迁移学习的方法, 采用深度特征结合 SVM 的方法在病害分类任务中表现更为出色。Pan 等^[5]提出了一个关键问题: 如何在复杂场景中, 仅依赖有限标注图像快速而准确地识别疾病。为应对这一挑战, 开发了一种名为 RiceNet 的两阶段方法, 用于识别水稻的 4 种重要病害, 包括水稻穗颈瘟病、水稻黑穗病、水稻叶瘟病和水稻茎瘟病。第 1 阶段, 使用 YOLOX 来检测水稻中的病害部位, 并根据检测结果对原始水稻病害图像进行裁剪, 从而创建了新的水稻病害斑块数据集。检测阶段, YOLOX 的平均精度与其他方法相比, 表现出最佳的检测性能。第 2 阶段采用了 Siamese Network 来识别第 1 阶段生成的水稻病斑数据集。Siamese Network 实现了卓越的识别准确率, 超过了其他模型。实验结果表明: 所提出的 RiceNet 模型在水稻病害检测方

收稿日期: 2023-11-02

基金项目: 黑龙江省农业科技创新跨越工程项目 (CX22YQ17)

作者简介: 崔佳鹏 (1987-), 男, 黑龙江绥化人, 工程师, 硕士, (E-mail) cuijiapeng@haas.cn。

通信作者: 付亚萍 (1979-), 女, 黑龙江大庆人, 高级工程师, 硕士, (E-mail) 1565415211@qq.com。

面胜过了目前的先进方法,可为水稻病害的快速准确检测提供有力支持。Yang 等^[6]关注了水稻叶部病害,这是导致水稻产量下降的一个主要因素。准确识别这些病害并采取相应的控制措施,对提高产量至关重要。因此,该研究提出了一种基于堆叠的集成学习模型,旨在高效而准确地识别水稻叶部病害。该模型构建了 4 个卷积神经网络(包括改进的 AlexNet、改进的 GoogLeNet、ResNet50 和 MobileNetV3)作为基本学习器,支持向量机(SVM)作为子学习器的堆叠集成学习模型。研究结果表明:所提出的模型比单一模型更为有效,在植物数据集上取得了显著成果,为植物病害识别提供了更为高效的方法。Liu 等^[7]针对水稻病害的预防和治理提出了一种新的神经网络模型,名为“注意力增强 DenseNet”。该模型包括病变特征提取器(ROI)提取算法,以及用于准确识别提取图中病变特征的 DenseNet 分类模型两个关键部分。研究表明,ROI 提取算法能够有效地突出水稻叶片中的病斑部位,从而使神经网络分类模型更加关注这些关键区域。与使用单一水稻病害分类模型相比,将 ROI 提取算法与 DenseNet 分类模型结合使用,可以显著提高水稻叶片病害的识别准确率。研究结果显示,这一方法有望在水稻病害的早期检测和管理中发挥积极作用。

上述研究充分证实了卷积神经网络在水稻病害识

别任务中的有效性,但鉴于水稻病害在不同生育期和生长环境下表现出不同特征,包括病斑位置和尺寸都有差异,使得传统卷积神经网络识别模型在水稻病害的准确识别方面存在模型迁移性能受限。因此,本研究以 5 种常见寒地水稻病害的病斑图像为研究对象,提出了改进型轻量级深度学习网络模型,旨在为水稻病害种类和病斑位置的精确快速识别提供一种新思路。

1 常见寒地水稻叶部病害图像数据集的建立

1.1 常见寒地水稻叶部病斑特征

在水稻生长过程中,主要的病害发生部位包括叶片、茎秆和穗部^[8]。同时,随着水稻生长阶段的变化,病害发生的部位会有所差异,且各个阶段表现出的病斑特征也不同,导致了水稻病害的多样性。本研究根据全国农技中心发布的 2022 年水稻重大病虫害防控技术方案,从北方单季粳稻种植区的重点防治病害目录中选取了包括白叶枯病、纹枯病、胡麻叶斑病、细菌性条斑病和稻瘟病 5 种常见寒地水稻叶部病害,其特征如表 1 所示。根据病害的病斑特征描述,构建常见寒地水稻叶部病害图像数据集。病斑特征描述可供深度学习网络模型在水稻病害图像识别中提供主观判别的视觉依据,有助于提高识别的准确性^[9]。

表 1 5 种常见寒地水稻叶部病害特征

Table 1 Five common characteristics of cold land rice leaf diseases

序号	病斑类别	病斑特征	发病位置
a	白叶枯病	最初呈现为黄色斑块,通常位于稻叶边缘。随着时间的推移,病斑会向稻叶中部扩展,形成纹状黄绿色或绿灰色斑块。随着病斑的进一步生长,颜色会逐渐变为灰白色。与此同时,受感染的稻叶可能会出现内卷的症状。	叶鞘、叶片
b	纹枯病	最初病斑发生在水稻植株靠近水面的叶鞘上,表现为不规则形状的椭圆形斑块,颜色为灰绿色或浅咖啡色。随后病斑会向水稻植株上部扩展,最终形成中央部位的灰白色斑块。	叶鞘、叶片
c	胡麻叶斑病	病斑首先出现在水稻叶鞘上,最初呈不规则椭圆形的深咖啡色斑块。随着病情加剧,斑块形状会逐渐变成中心部位呈现灰褐色的不规则斑块。在病情严重的部位,斑块常呈现深褐色。	叶鞘、叶片
d	细菌性条斑病	病害初期表现为暗绿色水浸状小斑,随后迅速扩展成暗绿至黄褐色细条状斑块,大小约为 1 mm×10 mm。在病害发展早期,条斑两端呈梭状深绿色斑块。由于该类型的病害进展迅速,因此梭状斑块在短时间内会扩展成深绿色条状斑纹。当病情严重时,条状斑纹可以相互连接形成大的枯白色斑块,甚至可能导致叶片内卷,使整个稻田呈现大片黄白色的症状。	叶片
e	稻瘟病	该病斑最初呈不规则深绿色小点状,出现在水稻叶片上,位置没有固定的模式。随着病情加剧,点状病斑开始扩大,变成椭圆形。在病情严重时,病斑上可能会生长出绿色的霉菌。这种类型病害生长速度非常快,对水稻危害程度相对较高。	叶鞘、叶片、稻穗

1.2 常见寒地水稻叶部病害图像数据集构建

深度神经网络模型的基本理念是模仿人脑的工作方式,从低级到高级逐渐提取和学习抽象的图像特征^[10]。通过训练这些模型来识别大量的病斑图像,使其能够在复杂情况下快速识别指定特征,从而完成图像的识别任务。由于缺乏现成的常见寒地水稻病害图像数据集,研究需要采集常见寒地水稻病害图像,并建立数据集供模型用于图像识别。本研究使用手持数码相机(佳能 EOS 5D Mark IV),在黑龙江省绥化市北林区黑龙江省农业科学院绥化分院水稻实验基地、黑龙江省齐齐哈尔市梅里斯达斡尔族区黑龙江省农业科学院齐齐哈尔分院水稻实验基地和黑龙江省安达市黑龙江八一农垦大学实验基地内,在不同日

期、不同气象条件下分别采集了上述 5 种病害的图像,图像分辨率为 $4\,096 \times 2\,160$, 格式为 JPEG, 部分病害图像如图 1 所示。最终,每种病害选取了 500 张有效的图像样本,并将图像分辨率预处理为 448×448 , 按病害种类将图像分别存储在相应的文件夹中。为增加样本数量,采用图像数据增强技术,将原始样本数据扩充到每类 2 000 张图像。在图像预处理方面,进行包括图像锐化、直方图均衡、以 X 轴和 Y 轴为基准的镜像翻转操作。此外,为满足病害的精准检测需求,基于 Labellmg 软件对数据集中的病害部分进行标记,采用 VOC 数据集的标记格式^[11]。最后,随机将数据集按照 3 : 1 的比例分成训练集和测试集,以便用于深度学习模型的训练和评估。




图 1 病害图像数据集

Fig. 1 Disease image dataset

2 病害分类网络模型构建

2.1 构建图像分类网络

由于卷积神经网络在农业应用中的迁移性受限,且农田环境中存在复杂的情况和许多干扰因素,传统的卷积神经网络图像分类模型难以同时保证高分类精度和时间效益^[12],因此不能直接采用现有主流卷积神经网络模型。本研究参考了主流卷积神经网络模型(如 AlexNet、GoogLeNet、VGG、ResNet 等^[13-16]),构建了一种适用于水稻白叶枯病、纹枯病、胡麻叶斑病、细菌性条斑病和稻瘟病等 5 种常见寒地水稻病害图像自动分类的网络模型。

该模型主要由连续的卷积层和 Inception 结构交替组成。需要注意的是,考虑到主流的残差网络主要用于解决深层网络模型中的梯度爆炸问题^[17],而本文中提出的网络模型层数相对较少,因此没有添加残差网络模块。

2.2 图像网络模型框架

图像分类网络模型总共包含 30 层网络结构,如

图 2 所示。第 1 层是输入层;第 2 层是卷积层,卷积核数量为 32,卷积核大小为 3×3 ,步长为 1,与此同时还使用了批归一化结构^[18]和 ReLU 激活函数^[19];第 3 层是类似于第 2 层的卷积层,卷积核数量为 64,步长为 2,因此得到的输出特征图空间尺寸下降为原来的 $1/2$,而通道数增加为原来的 1 倍;第 4 层是最大池化层,池化窗口大小为 2×2 ,步长为 1,用于突出纹理特征;第 5~11 层为 Inception 结构,用于扩展网络宽度,提高运行效率,增加特征提取;第 12 层是一个特征拼接层,可以将上面 Inception 结构获得的多支路特征进行聚合;第 13~15 层包括 2 个卷积层和 1 个最大池化层的组合,用于进一步降维和特征提取;第 16~22 层同样是一个 Inception 结构,用于进一步提高运行效率和深化特征提取;第 23 层仍为特征拼接层,作用与第 12 层相同;第 24~26 层与第 13 层到 15 层结构类似,用于进一步改变通道维数,提取不同尺度的特征;第 27 层是全连接层;第 28 层是 Dropout 层,用于提高泛化能力和减少过拟合;第 29 层是 Softmax 分类器;第 30 层是分类输出层。该网络模型的设计考虑了不同

层次的特征提取和维度降低,以提高分类性能和运行效率。






图 2 病害分类模型图

Fig. 2 Disease classification model diagram

在模型结构中,利用跨步卷积^[20]代替最大池化对图像进行降维,其原理如图 3 所示。



(a) 跨步卷积



(b) 池化层

图 3 降维操作原理

Fig. 3 Principle of Dimensionality Reduction

通过图 3 对比可以看出:跨步卷积操作与普通卷积操作类似,但不同之处在于:跨步卷积核在扫描图像时会略过部分区域,从而实现图像的降维,而最大池化则是在池化窗口遍历图像的过程中,仅保留窗口内最显著的特征信息,以实现降维。这两种操作代表了不同的图像降维和特征提取方式。为了确保特征模型中的多样性和丰富性,本文模型同时应用了这两种操作。

3 病斑目标检测网络模型构建

在水稻病斑目标检测过程中,不同病斑的特征差异明显,呈现多种形态,而且同一种病斑在不同的发病阶段也表现出不同的形态特征^[21]。因此,在进行病斑目标检测时,模型需要能够有效识别明显的目标和微小的目标。为此,在特征提取阶段需要尽可能地提取深层网络中的特征,以确保模型对不同尺寸和复杂度的病害目标都有较好的识别效果。

以上述图像分类网络作为病斑目标检测网络模型的骨干网络,经过改进,去除了最后的全连接层、Dropout 层、Softmax 层和输出层。然后,借鉴了 YOLOv3 网络模型的设计思路^[22],在第 14、23 和 26 层 3 个不同尺度的输出特征上进行特征提取,通过上下采样的方式将这些特征进行融合,以保证最终的目标检测具有良好的精度和高效性。该目标检测网络模型的结构如图 4 所示,图 4 中的数字表示相应类型的卷积块的数量,如果没有特别注明,默认为 1。

为了确保图像特征能够得到充分的提取和融合,模型保留了 YOLOv3 的上采样模块。不过,在上采样过程中,为了更好地保持原始图像特征,提高对图像细节的识别能力,将原有的双线性上采样操作改为转置卷积(Transposed Convolution, TC)^[23]。此外,在 3 个特征输出通道之间引入了降采样操作,通过空洞卷积

(Dilated Convolution, DC)^[24]来实现。在模型的特征提取部分,通过转置卷积和空洞卷积的结合,最大限

度地增加多尺度特征的融合,从而提高模型的检测能力,增强对明显目标和微小目标的识别效果。




图 4 病害目标检测模型图

Fig. 4 Disease target detection model diagram

转置卷积又被称为反卷积,可以视为卷积的逆过程,如图 5 所示。转置卷积的主要目的是将底层图像通过卷积操作还原到上一层或尺寸更大的图像,以突出图像中的微小特征。相对于简单的上采样,转置卷积操作能够挖掘每个像素的特征,还原更为精细的局部特征,因此更适用于小目标的检测工作。




图 5 转置卷积操作

Fig. 5 Transposed convolution operation

然而,反卷积容易产生不均匀的重叠,特别是当卷积核的大小不能被步长整除时,可能导致不均匀的重叠,产生棋盘格效应。为了缓解这种情况,将转置卷积的卷积核大小设置为 3×3,步长设置为 1,并在卷积后使用 ReLU 函数进行激活,有助于减轻棋盘格效应。

空洞卷积也称为膨胀卷积,是在标准卷积操作的基础上,通过在卷积核之间填充 0 来实现的。该操作扩大了深度神经网络模型的感受野,有助于捕捉多尺度信息。在目标检测中,融合多尺度信息可以提高目标检测的准确性。空洞卷积与普通卷积的区别如图 6 所示。




图 6 卷积和空洞卷积

Fig. 6 Convolution and hole convolution

空洞卷积在理论上相当于增加了卷积核的大小,

但由于它并不引入额外的有实际意义的参数,因此并不会增加计算量。空洞卷积的实际卷积核大小计算公式为

$$K = k + (k - 1) \times (r - 1) \quad (1)$$

其中, K 为实际卷积核的大小, k 为原始卷积核的大小, r 为空洞率。式(1)可以帮助理解空洞卷积如何在不引入额外参数的情况下扩大感受野。

由于空洞卷积的特性,它不能用于原始卷积核大小为 1×1 的卷积操作中,且一般情况下也不适用于原始卷积核大小为 2×2 的情况。因此,为了尽可能减少参数数量,本文引入的空洞卷积采用了 3×3 大小的卷积核,并选择了空洞率为 2。这样的设置既有助于捕捉多尺度信息,又不会引入过多的参数。

4 实验结果与分析

利用第 1 节中构建的常见寒地水稻叶部病害数据集,分别对图像分类模型和目标检测模型进行了训练。实验所使用的硬件配置包括 Intel(R) Xeon(R) Platinum 8352V CPU 和 NVIDIA GeForce RTX 4090 Super 显卡。操作系统为 Ubuntu 20.04,深度学习环境配置为 PyTorch 2.0.0 + CUDA 11.8 + CUDNN 8.9.2 + Python 3.8。

4.1 病害图像分类模型实验结果

在图像分类实验中,使用了 AlexNet、VGG-16、GoogLeNet 和 ResNet-18 等网络模型作为对比。实验设置训练周期为 300、样本批次大小为 32、优化器为 Adam、初始学习率为 0.01,并采用学习率递减策略逐步减小学习率。为了确保实验结果的一致性,在训练中没有使用预训练权重,所有模型都是从头开始训练的。图 7 为不同网络模型的训练损失随着迭代周期的增加而变化的趋势,用于比较网络模型的性能。




图 7 不同网络的训练损失

Fig. 7 Training loss for different networks

由图 7 可以看出:在前 40 个训练周期内,随着训练次数的增加,5 种不同模型的训练损失迅速下降。其中,本文提出的网络模型和 ResNet-18 随着训练周期的进一步增加,模型训练损失虽有小幅度波动,但整体趋于稳定;而 GoogLeNet 在经过前 180 个训练周期后,训练损失出现了显著下降,但在后续的训练中也存在较大波动。相比之下,VGG-16 和 AlexNet 表现较差,两个模型的训练损失在 300 个训练周期内始终未能达到一个相对稳定的状态。这种差异可能是因为 VGG-16 和 AlexNet 相对于其他模型来说网络较浅且结构相对简单,因此学习多尺度特征的能力较弱。

在测试阶段,使用了各网络模型中表现最好的模型参数,并使用水稻病斑的测试集图像进行了测试。评估指标选择了图像分类中常用的准确率 (Accuracy)、召回率 (Recall)、精度 (Precision) 和 F1-Score 等

4 个指标进行评估,计算公式为

$$Ac = \frac{TP+TN}{TP+FN+FP+TN} \times 100\% \quad (2)$$

$$Re = \frac{TP}{TP+FN} \times 100\% \quad (3)$$

$$Pr = \frac{TP}{TP+FP} \times 100\% \quad (4)$$

$$F1-SCORE = 2 \times \frac{Re \times Pr}{Re + Pr} \quad (5)$$

其中,Ac 为准确率,Re 为召回率,Pr 为精度,TP 为真阳性样本数量 (模型正确分类的样本数),TN 为真阴性样本数量 (模型正确排除的样本数),FN 为假阴性样本数量 (模型漏掉的样本数),FP 为假阳性样本数量 (模型错误分类的样本数)。

以水稻纹枯病为例,在对纹枯病图像进行评估时,TP 为正确识别为纹枯病的样本数量,TN 为将其其他病害图像正确识别为对应病害的数量,FN 表示将数据集中的纹枯病图像错误地识别为其他病害,FP 表示将数据集中其他病害的图像错误地识别为纹枯病。这些指标用于衡量模型在纹枯病识别任务中的性能。

利用上述提到的 5 种图像分类模型对测试集图像进行测试,然后根据准确率 (Accuracy)、召回率 (Recall)、精度 (Precision) 和 F1-Score 等 4 种评价指标对结果进行了统计,如图 8 所示。这些指标用于评估每个模型在常见寒地水稻叶部病害分类任务中的表现。




图 8 测试结果

Fig. 8 Test Results a Average indicator b Single indicator

由图 8 可以看出:采用本文提出的图像分类网络模型对 5 种病害进行识别分类时,在大多数方面表现

出较明显的优势,平均召回率、平均精度、平均 F1-Score 和总体准确率分别达到了 93.64%、93.74%、93.77% 和 93.64%。本文提出的网络模型对各类病害进行测试后,生成的混淆矩阵如图 9 所示。混淆矩阵通常用于可视化显示模型在不同类别上的分类结果,可以帮助评估模型的性能。




图 9 本文提出的网络模型混淆矩阵

Fig. 9 Confusion matrix of the network model proposed in this paper

4.2 病斑目标检测模型实验结果

在实验中,使用了标记的数据集进行了训练和测试,并选择了 SSD、Faster-RCNN、YOLOv3 和 YOLOv4 算法作为对比。实验中采用了两种训练方式,即冻结训练和非冻结训练。冻结训练的迭代次数设置为 250,非冻结训练的迭代次数设置为 250,样本批次大小为 16,并使用了与图像分类网络相同的优化器和学习率设置。为了确保实验结果的一致性,在训练中没有使用预训练权重,所有模型都是从头开始训练的。

在测试目标检测模型的性能时,使用了以下评价指标:mAP (Mean Average Precision) 为平均精度均值,用于评估模型在不同类别上的检测精度;FPS (Frames Per Second) 为每秒处理的图像帧数,用于评估模型的运行速度;FAR (False Alarm Rate, 虚警率) 为模型误报的比率,即模型错误地将正常物体识别为病斑的比例;DR (Detection Rate, 检测率) 为模型正确检测到病斑的比率,即模型成功检测到实际存在的病斑比例。这些指标用于全面评估目标检测模型的性能,包括准确性、速度和模型的虚警率和检测率。

在计算 mAP 时,考虑了数据集中的所有分类类别。mAP 是各类别的平均检测精度 (Average Precision, AP) 的均值。AP 是在不同召回率 (Recall) 下的平均检测精度,对每个类别都计算 1 个 AP 值,然后取

所有类别 AP 值的平均值,即得到 mAP。

$$mAP = \frac{\sum_{i=1}^n AP(i)}{n} \quad (6)$$

式中: n 为数据集中的分类类别数,AP 为每个类别在不同召回率下的平均检测精度。

计算 mAP 的过程考虑了各个类别的检测性能,并给出了一个整体的评估值,以更全面地评价模型的性能,即

$$FAR = \frac{AP_i}{TP_i} \quad (7)$$

$$DR = \frac{DP_i}{TP_i} \quad (8)$$

式中: AP_i 为存在虚警检测的测试集图像数量, DP_i 为检测到图像中所有病斑的图像数量, TP_i 为测试集图像的总数量。这些指标用于评估目标检测模型的性能,特别是在考虑虚警检测和漏检的情况下,以提供更全面的性能评估。

不同算法的检测效果如表 2 所示。表 2 中的数据表明,本文改进的目标检测算法在常见寒地水稻叶部病斑目标检测问题上表现出了良好的性能。其平均检测精度 (mAP) 达到了 89.79%,在一定程度上超过了传统的 YOLOv3 算法,并且在虚警率方面表现出较大的优势,仅为 5.01%。然而,DR 略低,为 94.94%;FPS 也略低,为 64.9。这些结果表明:本文改进的算法在检测精度和虚警率方面具有明显的优势,适用于实际的水稻病斑目标检测任务。

表 2 不同算法的检测效果

Table 2 Detection effect of different algorithms

模型	mAP/%	DR/%	FAR/%	FPS
SSD	79.36	90.32	9.21	55.4
Faster-RCNN	83.56	91.58	7.32	33.6
YOLOv3	84.86	94.56	7.58	61.2
YOLOv4	86.57	95.91	5.17	67.3
改进 YOLOv3	89.79	94.94	5.01	64.9

注:表中标记的值为识别效果最好的结果。

模型对各类病斑的目标检测效果如图 10 所示。由图 10 可以看出:本文提出的模型在病斑目标检测任务上具有很高的准确性,成功检测到了多个不同类型的病害。这进一步证明了该模型在常见寒地水稻

叶部病斑目标检测方面的有效性。同时,还发现在算法的改进中,通过采用多尺度特征信息融合操作,可以有助于提高检测精度并降低虚警率。然而,由于所使用的主干网络较浅且没有使用残差模块,可能会导致一定的漏检情况,从而影响检测率。综合考虑了多个评价指标,改进的网络模型仍在水稻病斑目标检测方面表现出一定的优势,并能够满足田间环境下水稻叶部病斑的实时检测需求。




图 10 病斑目标检测测试结果

Fig. 10 Spot detection test results

4.3 病害分类和病斑检测对比分析

文中进行了两组实验:一组是关于水稻病害的图像分类,另一组是关于水稻病斑的目标检测。实验结果表明:图像分类网络在对 5 种水稻病害图像进行分类时,准确率可达 93.64% 以上,而病斑目标检测的 mAP 仅为 89.79%。这表明,图像分类的效果明显优于目标检测的效果。这种差异可以解释为两种算法面向不同的任务。图像分类网络仅需要判断图像中包含的病害种类,而不需要精确地标记病斑的位置。因此,图像分类网络可以提取更多图像信息,包括叶片的信息和除病斑之外的其他图像信息。相比之下,病斑目标检测需要在分类的基础上精确地标记出病斑在图像中的位置,增加了更多困难和干扰因素。目标检测可能受到病斑位置标记错误、病斑漏标记等因素的影响,同时也需要应对同一种病斑的不同形式和不同清晰度的病斑,增加了检测的难度。

总的来说,图像分类适用于粗略的病害分类任务,而目标检测适用于需要精确标记位置信息的任务;但由于其复杂性,目标检测的精度可能略低于图

像分类,选择何种方法取决于具体任务的需求。

针对水稻病斑检测识别可以看出:病害爆发初期,病害特征通常不太明显,而且大范围的检测难以捕捉到病害信息。在这种情况下,通过人工拍摄等方式,可以有针对性地获取单幅图像中包含的病斑信息,有助于提高病害的识别和分类精度。此外,稻田环境的复杂性和目前农机设备的局限性使得水稻多种病害一起爆发时,病害分布往往具有随机性,没有明显的病害分界线。此时,精确的病害目标检测可以帮助确定病害的具体位置,有助于针对单一病害进行精准的农药喷洒。这种精确作业有望提高农田管理的效率和农产品的产量。

因此,图像分类适用于对病害程度的初步判断和分类,而精确的病害目标检测适用于需要精准作业的情况,两者可以在不同的场景中发挥作用,根据具体需求选择合适的方法。

5 结 论

针对 5 种常见寒地水稻叶部病害图像数据的识别和检测问题,首先创建了包括水稻白叶枯病、纹枯病、胡麻叶斑病、细菌性条斑病和稻瘟病在内的 5 种常见寒地水稻病害图像数据集。然后,针对病害识别任务提出了一种轻量级的图像分类网络模型,并以此模型为基础对 YOLOv3 算法进行改进,提出了一种适用于病斑检测任务的目标检测模型。实验结果表明:病害图像分类网络模型和病斑目标检测模型都表现出一定的优势,能够迅速且准确地对这 5 种常见寒地水稻病害图像进行分类识别和目标检测。未来的研究可以考虑进一步完善水稻病害数据集以提高识别和检测效果,并将其部署到边缘智能终端。

参考文献:

- [1] 赵春江. 农业知识智能服务技术综述[J]. 智慧农业(中英文), 2023, 5(2): 126-148.
- [2] KOTWAL J, KASHYAP R, PATHAN S. Agricultural plant diseases identification: from traditional approach to deep learning[J]. Materials today: proceedings, 2023 (80): 344-356.
- [3] 周长建, 宋佳, 向文胜. 基于人工智能的作物病害识别研究进展[J]. 植物保护学报, 2022, 49(1): 316-324.
- [4] SETHY K P, BARPANDA K N, RATH K A, et al. Deep feature based rice leaf disease identification using support vector machine[J]. Computers and electronics in agriculture, 2020 (175): 105527.

- [5] PAN J C, WANG T Y, WU Q F. RiceNet: A two stage machine learning method for rice disease identification[J]. Bio-systems engineering, 2023(225):25-40.
- [6] YANG L, YU X Y, ZHANG S P, et al. Stacking-based and improved convolutional neural network: a new approach in rice leaf disease identification[J]. Frontiers in plant science, 2023(14):1165940.
- [7] LIU W F, YU L, LUO J X. A hybrid attention-enhanced DenseNet neural network model based on improved U-Net for rice leaf disease identification[J]. Frontiers in plant science, 2022(13):922809.
- [8] 亓璐, 张涛, 曾娟, 等. 近年我国水稻五大产区主要病害发生情况分析[J]. 中国植保导刊, 2021, 41(4):37-42, 65.
- [9] 傅强, 黄世文. 图说水稻病虫害诊断与防治[M]. 北京: 机械工业出版社, 2019:2-83.
- [10] 张珂, 冯晓晗, 郭玉荣, 等. 图像分类的深度卷积神经网络模型综述[J]. 中国图象图形学报, 2021, 26(10):2305-2325.
- [11] EVERINGHAM M, VAN GOOL L, WILLIAMS C K I, et al. The pascal visual object classes (VOC) challenge[J]. International journal of computer vision, 2010, 88(2):303-338.
- [12] 朱云, 凌志刚, 张雨强. 机器视觉技术研究进展及展望[J]. 图学学报, 2020, 41(6):871-890.
- [13] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6):84-90.
- [14] 万军杰, 祁力钧, 卢中奥, 等. 基于迁移学习的 GoogLeNet 果园病虫害识别与分级[J]. 中国农业大学学报, 2021, 26(11):209-221.
- [15] 张建华, 孔繁涛, 吴建寨, 等. 基于改进 VGG 卷积神经网络的棉花病害识别模型[J]. 中国农业大学学报, 2018, 23(11):161-171.
- [16] 郭玥秀, 杨伟, 刘琦, 等. 残差网络研究综述[J]. 计算机应用研究, 2020, 37(5):1292-1297.
- [17] ZHUANG J, LI X, BAGAVATHIANNAN M, et al. Evaluation of different deep convolutional neural networks for detection of broadleaf weed seedlings in wheat[J]. Pest management science, 2022, 78(2):521-529.
- [18] 刘建伟, 赵会丹, 罗雄麟, 等. 深度学习批归一化及其相关算法研究进展[J]. 自动化学报, 2020, 46(6):1090-1120.
- [19] GLOROT X, BORDES A, BENGIO Y. Deep Sparse Rectifier Neural Networks[J]. Journal of machine learning Research, 2011:315-323.
- [20] LO GIUDICE A, RONSIVALLE V, SPAMPINATO C, et al. Fully automatic segmentation of the mandible based on convolutional neural networks (CNNs) [J]. Orthodontics & craniofacial research, 2021, 24:100-107.
- [21] 张凝, 杨贵军, 赵春江, 等. 作物病虫害高光谱遥感进展与展望[J]. 遥感学报, 2021, 25(1):403-422.
- [22] 郭阳, 许贝贝, 陈桂鹏, 等. 基于卷积神经网络的水稻虫害识别方法[J]. 中国农业科技导报, 2021, 23(11):99-109.
- [23] 刘腊梅, 王晓娜, 刘万军, 等. 融合转置卷积与深度残差图像语义分割方法[J]. 计算机科学与探索, 2022, 16(9):2132-2142.
- [24] 曲长波, 姜思瑶, 吴德阳. 空洞卷积的多尺度语义分割网络[J]. 计算机工程与应用, 2019, 55(24):91-95.

Recognition of Common Leaf Diseases in Cold-Tolerant Rice Based on Improving Convolutional Neural Networks

Cui Jiapeng¹, Xu Hongyang¹, Fu Yaping²

(1. Branch of Suihua, Heilongjiang Academy of Agricultural Mechanization Sciences, Suihua 152054, China; 2. Soybean Research Institute, Heilongjiang Academy of Agricultural Sciences, Harbin 150086, China)

Abstract: The traditional convolutional neural network had limitations in the identification of rice diseases, especially in the identification of the location of rice disease spots in cold regions. To this end, an improved lightweight deep learning network model was proposed, a data set containing five common rice leaf disease images in cold regions was established, and a disease classification and disease spot target detection network model was constructed. The image classification network was embedded in the YOLOv3 target detection network, and the feature extraction part of the model was optimized. Transposed convolution and dilated convolution were used for upsampling and downsampling. Finally, the improved YOLOv3 model was compared with the traditional convolutional neural network model. The experimental results showed that the disease classification model performed well on all indicators. The average recall rate, average accuracy, average F1-Score and overall accuracy were 93.64 %, 93.74 %, 93.77 % and 93.64 %, respectively. The improved YOLOv3

model also performed well in the detection of disease spots. The mean Average Precision (mAP) reached 89.79 %, the detection rate (DR) reached 94.94 %, and the detection speed reached 64.9 f/s. The comprehensive performance of improved YOLOv3 was obviously better than the traditional YOLOv3 algorithm. It provided a new way for the accurate and rapid identification of rice diseases and had great significance for the monitoring and prevention of rice diseases.

Key words: cold-tolerant rice disease lesion recognition; convolutional neural networks; object detection; image classification

(上接第 232 页)

Abstract ID:1003-188X(2025)10-0226-EA

Phenotyping of Field Cabbage Based on Three-dimensional Reconstruction of Canopy by Drone(UAV)

Ren Tianyi¹, Peng Bo¹, Yuan Shuai², Fan Xiaofei¹

(1. College of Electrical and Mechanical Engineering, Hebei Agricultural University, Baoding 071000, China; 2. College of Horticulture, Hebei Agricultural University, Baoding 071000, China)

Abstract: Plant phenotyping is of great importance in the field of agricultural science and plant breeding, and traditional manual measurements are inefficient, low-precision, poorly reproducible and limited. In order to achieve efficient, accurate and large-scale acquisition of plant phenotypic data, proposed a high-throughput automatic method for obtaining the plant length, plant width and height of an individual cabbage plant based on unmanned aerial vehicle (UAV) RGB images. The method utilized RGB images of field cabbages captured by UAVs and reconstructed the 3D point cloud of the cabbage growth scene by the Structure for Motion Recovery (SfM) algorithm. By training a point cloud semantic segmentation network, it was able to segment the cabbage canopy region from the field plot background. Then, the K-Means clustering algorithm was used to extract the point cloud of an individual cabbage plant model, and the plant length, width and height of the cabbage plant were calculated by using the enclosing box method. To verify the accuracy of the method, the researchers compared the obtained cabbage plant length, width and height with manual measurements. The results showed that the proposed method obtained satisfactory results by the coefficient of determination R^2 (0.943 37, 0.905 54 and 0.924 61, respectively) compared with the manual measurements. It provided a scientific and reliable phenotyping tool for research on digital breeding of Chinese cabbage. This automated high-throughput method was expected to facilitate research and practice in the field of agricultural science and plant breeding, and support the improvement of crop quality and increase in yield.

Key words: cabbage phenotype; UAV RGB images; 3D point cloud; point cloud semantic segmentation; K-Means clustering; axis-aligned bracket box