

卷积神经网络在图像分类和目标检测应用综述

周俊宇, 赵艳明

ZHOU Junyu, ZHAO Yanming

中国传媒大学 理工学部, 北京 100024

College of Science and Technology, Communication University of China, Beijing 100024, China

ZHOU Junyu, ZHAO Yanming. Application of convolution neural network in image classification and object detection. Computer Engineering and Applications, 2017, 53(13):34-41.

Abstract: Convolutional Neural Network (CNN) has strong ability in finding characteristics of pictures. Recent years, with the arrival of big data era and the development of the computers, CNN has made great breakthrough in the field of image classification, object detection and so on. It has been widely studied in computer vision. This paper summarizes the theory of CNN, as well as the research and typical models on image classification, object detection. Finally, some existing problems in the CNN are analyzed, with forecasting the future development of CNN as well.

Key words: Convolutional Neural Network (CNN); image classification; object detection

摘 要: 卷积神经网络具有强大的特征学习能力, 随着大数据时代的到来和计算机能力的提升, 近年来卷积神经网络在图像识别、目标检测等领域取得了突破性进展, 掀起了新的研究热潮。综述卷积神经网络的基本原理, 以及其在图像分类、目标检测上的研究进展和典型模型, 最后分析了卷积神经网络目前的问题, 并展望了未来的发展方向。

关键词: 卷积神经网络; 图像分类; 目标检测

文献标志码: A **中图分类号:** TP183 doi:10.3778/j.issn.1002-8331.1703-0362

1 引言

对图像的特征提取一直以来都是研究的重点问题, 赋予计算机像动物一样的视觉能力是研究人员梦寐以求的成果。传统的图像特征提取算法更多的是针对特定的问题, 进行专门的人工设定, 这种方法泛化能力弱, 可移植性差, 准确度相对较差。20世纪60年代, Hubel等人通过对猫的大脑视觉皮层研究发现, 生物的视觉系统是通过多层次的感受野(Receptive Field)逐层激发实现的^[1]。对动物视觉机理的深入研究启发研究人员思考是否可以设计出类似的算法, 赋予机器识别理解图像的能力, 由此卷积神经网络(Convolutional Neural Networks, CNN)应运而生。

20世纪80年代, Fukushima提出了第一个多层次的神经网络模型Neocognitron^[2]。20世纪90年代, Lecun等在研究手写识别问题上, 构建了LeNet-5模型^[3], 该模型首次提出了使用梯度反向传播算法(Back Propagation algorithm, BP)对卷积神经网络进行有监督训练。LeNet-5

当时在MNIST数据集上取得最好的识别效果, 其模型采用交替连接的卷积层和池化层, 最后通过全连接层分类, 确立了现代卷积神经网络的基础。

缺乏大规模训练数据, 又受限于理论基础和计算机计算能力, LeNet-5在复杂图像上的识别结果并不理想。2006年, 加拿大多伦多大学教授Hinton提出深度学习的概念, 并提出: 多隐层神经网络具有更为优异的特征学习能力, 并且其在训练上的复杂度可以通过逐层初始化来有效缓解^[4]。2011年, 研究人员实现了在GPU上的卷积运算, 从而大大提高了网络的计算能力, 相比CPU运算速度提升了2~24倍^[5]。

卷积神经网络依靠网络本身, 通过对训练数据的学习, 提取数据特征^[6]。随着大数据时代的到来, 卷积神经网络在图像处理中越来越体现出不可替代的优越性, 在图像识别、目标检测、图像分割、目标追踪等领域取得了飞跃性的进展。

作者简介: 周俊宇(1994—), 男, 硕士研究生, 研究领域为数字图像处理、深度学习, E-mail: zjyaabcc@126.com; 赵艳明(1973—), 女, 博士, 副教授, 研究领域为数字图像处理、音频处理。

收稿日期: 2017-03-21 **修回日期:** 2017-05-15 **文章编号:** 1002-8331(2017)13-0034-08

2 卷积神经网络介绍

卷积神经网络是深度神经网络的一种,过去几年,深度学习在解决诸如视觉识别、语音识别和自然语言处理等很多问题方面都表现出色。在不同类型的神经网络当中,卷积神经网络是得到最深入研究的,已成为当前图像识别领域的研究热点。

2.1 基本网络结构

卷积神经网络网络包括输入层、卷积层、池化层、全连接层和分类器。图1给出了一个用于图像分类的网络。

卷积层包含若干组参数可以学习的卷积核,这些参数是卷积神经网络训练的核心。当前层的卷积核对输入的一组图片做卷积运算,再经过激活函数得到新的特征图像(feature map)。在卷积层中输出的新的像素点可由公式(1)计算得出:

$$\begin{aligned} x_j^{l-1} &= f(u_j^l) \\ u_j^l &= \sum_{i \in M_j} x_i^{l-1} * W_{ij}^l + b_j^l \end{aligned} \quad (1)$$

其中, $f(\cdot)$ 代表激活函数, x_i^{l-1} 代表上一层特征图像的某个像素值, W_{ij}^l 代表卷积核, $*$ 代表卷积运算;考虑到本层输出可以与上一层多个特征图像关联, M_j 表示参与运算的上一层的特征图像的子集; b_j^l 代表偏置项,上标 l 表示第 l 层。

卷积层后一般接入池化层来减小数据量,较常见的有最大值池化和平均值池化。经过交替的卷积层和池化层之后,已经获得了高度抽象的特征图像,全连接层可以看作是设计与最后一层特征图像尺寸相同的卷积核,而将这些二维特征图像“抹平”成一维数组,对提取的特征进行分类。

2.2 基本工作原理

卷积神经网络对卷积核参数的学习训练是通过梯度反向传播算法实现的,该算法是一种有监督学习算法。假设网络的训练尚未完善,输入信号的训练输出和实际输出会有一定误差,误差在梯度下降算法中逐层传播,逐层更新网络参数。设样例 (x, y) 的代价函数为 $J(W, b; x, y)$:

$$J(W, b; x, y) = \frac{1}{2} \|h_{W,b}(x) - y\|^2 \quad (2)$$

实际中增加 L_2 范数控制过拟合现象:

$$J(W, b) = J(W, b; x, y) + \frac{\lambda}{2} W^T W \quad (3)$$

其中, $h_{W,b}(x)$ 表示输入样本 x 经过网络后的输出, y 表示样本的标签真值, λ 表示控制强度。训练的目标显然是让代价函数尽可能的小,因此要不断更新每一层的权重 W 和偏置项 b ,任意一层(假设为 l 层)的权重更新如下:

$$\begin{cases} W_{ij}^l = W_{ij}^l - \alpha \frac{\partial}{\partial W_{ij}^l} J(W, b) \\ b_i^l = b_i^l - \alpha \frac{\partial}{\partial b_i^l} J(W, b) \end{cases} \quad (4)$$

3 卷积神经网络在图像分类的应用

图像分类是通过对图像整体的分析,预测图像的类别。图像分类是计算机视觉的挑战领域之一,每年有赛事 Imagenet Large Scale Visual Recognition Challenge (ILSVRC)^[7],来供各种算法挑战分类极限。在ILSVRC 2012中,来自多伦多大学的 Alex Krizhevsky 团队设计出卷积神经网络 AlexNet,将测试的 top-5 error 下降到 15.3%^[8],而采取传统方法做分类的第二名 top-5 error 为 26.2%,显示了CNN强大的优势。此后,不断有更加高效、准确的模型出现,如牛津大学的VGG^[9],谷歌研究院的GoogLeNet^[10]等。近年来的优秀模型甚至突破了人眼识别的平均错误率,展示了卷积神经网络在图像分类上的强大优势。

卷积神经网络需带有标签的数据集做有监督的网络训练,目前有许多用于图像分类的带标签数据集,如 ImageNet^[11]、CIFAR10/100^[12]、NORB^[13]、Caltech-101/256^[14]等。ILSVRC使用的就 ImageNet 数据集的子集,该子集包含 1 000 个分类,128 万张测试图片^[15]。

3.1 AlexNet

Lenet-5 虽然在识别手写字方面取得了不错的效果,但是在其他领域确鲜有进展,除去大规模训练需要的硬件难以支持外,过拟合问题也限制了卷积神经网络的应用^[13]。过拟合(over-fitting),是指模型在训练过程中过度拟合训练集,影响模型的泛化性,使得模型在测试集上表现不理想,过拟合的效果如图2所示。卷积神经网络结构复杂,参数众多,容易产生过拟合现象。

减少过拟合主要的思路是将网络变得更加“稀疏”,网络的连接更加随机化。Hinton 等人^[16]认为,在卷积神经网络训练的过程中随机的忽略一些节点的影响,可以




图1 卷积神经网络基本结构




图2 过拟合示意图

有效地提高网络的泛化性,这种做法称为 dropout。如图3所示,只保留 50% 的网络连接后,模型变得简明。




图3 dropout 示意图

针对传统卷积神经网络训练难以收敛的问题, Alex 等人在分析对比后提出了新的激活函数 ReLu, 其数学表达式为:

$$f(x) = \max(0, x) \quad (5)$$

传统的激活函数 sigmoid、tanh 等, 在输入很大或者很小的时候, 梯度会变得极小^[17]。反向传播时参数的更新需要乘上激活函数的导数, 这样使得学习速率急速下降。采用 ReLu 激活函数, 可以避免在输入较大的时候梯度消失的问题。图4所示是激活函数 ReLu 与 tanh 在 CIFAR-10 上的训练对比, 以错误率 0.25 为标准, ReLu 的收敛速度是 tanh 的 6 倍^[18]。




图4 ReLu 与 tanh 对比

AlexNet 最终的神经网络结构共有 7 层, 包含 5 个卷积层和 2 个全连接层, 有约 65 万个神经元和 6 000 万个可训练的参数。采用 dropout 和激活函数 ReLu 等技术, 训练环境为 2 路 GTX580, 对 128 万测试图片的训练周期在 5~6 天, 相比于之前的卷积神经网络, 在准确度和训练时间上都有了明显提升。

手写字图片输入尺寸为 28×28, 图像分类的图片为 224×224, 尺寸更大, 信息更为丰富; Lenet-5 使用两个卷积层就可以将原始图转化为尺度合适的特征图, AlexNet 则用 5 个卷积层才做到类似的效果。为了快速

缩小图片尺寸, AlexNet 设计了 11×11 巨大的卷积核。大卷积核的引入造成两个问题: 一是大卷积核要学习的参数过多; 二是图像的快速缩小可能意味着细节特征的丢失, 这也是 AlexNet 明显的弊端。

3.2 其他代表性的网络结构

3.2.1 VGGnet

针对 AlexNet 的大卷积核问题, 牛津大学的 Simonyan 等人通过实验发现, 可以用若干较小的卷积核代替大的卷积核, 并能得到更好的实验结果。一个 7×7 的卷积核可以看作是 3 层 3×3 卷积核的叠加, 一个 7×7 的卷积核有 49 个需要学习的参数, 只能提供一层特征图像, 一种感受野; 3 层 3×3 卷积核只有 27 个参数, 提供 3 层不同尺度下的特征图像, 3 种感受野^[9]。

Karen 等提出的 VGGnet 几乎全部采用 3×3 的卷积核, 同时在若干卷积层后加入池化层, 而不是在每一个卷积层后立刻池化, 从多方面保证网络的深度。VGGnet 证明了网络层数增加有利于提高图像分类的准确度, 这种增加并非是无限制的, 过多的层数会产生网络退化问题^[18], 影响测试结果。最终 VGGnet 的层数确定在 16 层和 19 层两个版本。

3.2.2 GoogLeNet

不同尺寸的卷积核意味着不同大小的感受野, VGGnet 已经证明不同感受野有助于提高分类精度, 谷歌研究院的 GoogLeNet 更进一步, 在同一层中插入不同大小的卷积核, 这样的结构被称为 Inception^[10]。如图5所示, 在同一层内插入 1×1, 3×3, 5×5 不同尺寸的卷积核, 最后拼接使得不同尺度的特征图像相互融合。在 3×3, 5×5 之前加入 1×1 的卷积核主要目的是降维^[19], 降维可以减少参数量。




图5 Inception 结构

Inception 可以看作是对卷积神经网络结构的优化, GoogLeNet 训练的参数量仅为 AlexNet 的 1/12, 却取得了更准确的结果。GoogLeNet 是 ILSVRC2014 分类比赛冠军, 网络深度达 22 层。

3.2.3 Batch Normalization

由于卷积神经网络训练样本过大, 一般训练时是将数据一批 (batch) 一批送入网络训练。神经网络学习的本质就是数据分布, 若某一个 batch 与另一个 batch 数据

差别过大,需要重新学习参数来适应这些变化,从而大大影响训练速度^[20]。

为了解决这一问题,谷歌研究院在2015年提出Batch Normalization(BN)^[21],在网络每一层输入之前加入一个归一化层,对之前的数据作归一化处理后再让当前层训练。归一化的公式改变为:

$$\bar{x}^{(k)} = \frac{x^{(k)} - E(x^{(k)})}{\sqrt{\text{var}(x^{(k)})}} \quad (6)$$

$E(x^{(k)})$ 代表所有训练集平均值, $\text{var}(x^{(k)})$ 代表所有训练集方差, $\bar{x}^{(k)}$ 代表某个训练的 batch,也就是意味着不管使用哪一组 batch,样本的方差和均值都是固定的。

Batch Normalization 对于网络的影响:一是加快了训练速度,BN层对数据的处理将每一层的均值方差固定减小了不同 batch 的区别;二是有助于梯度传播,主要是降低了参数大小及参数初始化大小的影响,这就可以使用很高的学习率参数而不至于系统发散;三是提高模型的泛化性,实验证明,引入BN层后,减小 dropout 的比例甚至删去 dropout 过程,并不影响测试结果。

3.2.4 深度残差网络

从 AlexNet 的 7 层网络,再到 VGG 的 19 层网络,GoogLeNet 的 22 层网络,似乎表明卷积神经网络层次越深,效果越好。然而更深的网络必然会面对梯度弥散问题。梯度下降法在使用随机初始化权重的深度网络上效果不好的技术原因是梯度会变得非常小^[18,22]。具体而言,可设一个简单的神经网络,如图6所示。




图6 简单的神经网络

图中, b_1, b_2 等代表权重, w_1, w_2 等代表偏置, C 代表代价函数。由 2.2 节所述,可以推导出 b_1 的更新公式:

$$b_1 = b_1 - \alpha \frac{\partial C}{\partial b_1} \quad (7)$$

其中:

$$\frac{\partial C}{\partial b_1} = f'(z_1) \times w_2 \times f'(z_2) \times w_3 \times f'(z_3) \times w_4 \times f'(z_4) \times \frac{\partial C}{\partial a_4} \quad (8)$$

a_4 代表网络第四层产生的输出。

由于公式(8)是连乘式,且其中所有项均为小于1的数,在网络层数过多情况下最终结果必然极小,由公式(7)可知, b_1 将变化极小,影响了网络的收敛速度,此问题最终会导致网络的退化。

针对梯度弥散问题,何凯明等人提出了深度残差网络。深度残差网络通过 shortcut 直接将低层的特征图 x 映射到高层,高层的输出变为底层映射和原始输出的叠加,结构如图7所示。网络的训练中引入低层网络的先验,考虑极端的情况,若 x 已经是一个近于完美的映射,

在后续的训练中当前层的梯度理论上会变得很小,在反向传播中会继续影响之前层的系数更新,而引入图7的结构后,输出项 x 的存在使得总体的梯度不会消失,从而保证了更深网络的性能^[23]。




图7 残差单元

深度残差网络在 ILSVRC2015 中以 top-5 error 为 3.57% 夺得冠军,这一结果超过了人眼识别率(5.1%)^[24],其网络深度多达 152 层。尽管如此,深度残差网络模型过于庞大复杂,如何给卷积神经网络“瘦身”,优化其结构,必然是未来研究的热点。

4 卷积神经网络在目标检测的应用

目标检测的主要目的是从图片中检测并定位特定的多个目标。传统检测模型通常采用人工特征提取方法获得目标的特征描述,然后输入到一个分类器中学习分类规则。传统的方法弊端:一是人工提取特征方法复杂,并需要对检测目标有一定的先验知识;二是分离特征提取和分类训练,若特征提取不够好,训练就难以有好效果;三是高度依赖具体任务,可移植性差,一旦检测目标有较大变动,就要重新设计算法^[25]。

卷积神经网络通过卷积运算让计算机自动从图像中提取目标特征,这样获得的特征更自然,并且通用性好,对一定程度的扭曲形变有良好的鲁棒性,并且在图像分类上取得了巨大成功,使得人们开始研究它在计算机视觉其他领域的效果。2014 年, Girshick 基于卷积神经网络设计了 R-CNN 模型^[26],该模型在 PASCAL VOC 的目标检测测试^[27]中平均准确率均值(mean Average Precision, mAP)达到 62.4%,比传统算法高出近 20%。随后研究人员根据 R-CNN 的不足做一步步的改进,其中 Faster-R-CNN^[28]在提升 mAP 同时,将测试速度提升到每秒 5 帧,比 R-CNN 测试快上百倍。同时, Facebook 的人工智能实验室完全打破传统目标检测的思路,设计了更快、更轻巧的模型 YOLO^[29],其最快版本的 fast YOLO 测试速度可以达到每秒 155 帧。

4.1 基于目标候选区域的模型——R-CNN

传统的目标检测一般分为三步,即选择目标候选区域,对候选区域进行特征提取,最后将提取到的特征放入分类器。R-CNN 的网络结构^[21]如图8所示,其中只有特征提取用卷积神经网络。相比于传统方法,R-CNN 主要考虑的是:完全可以用卷积神经网络代替传统的图形特征提取部分,因为前者找到的特征更有普遍适用性。




图8 R-CNN 网络结构

R-CNN 相比于传统方法, mAP 有了明显的提高。但由于每幅图片要进行 2 000 次卷积运算, 因此算法的测试速度过慢, 处理一幅图片的平均时长为 34 s, 时间开销大。R-CNN 针对候选区域筛选、特征提取、分类, 完全用不同的方法实现, 训练步骤繁琐, 需要转存每一步得到的数据, 空间开销大。

4.2 对 R-CNN 的改进结构

4.2.1 SPPnet

基本的卷积神经网络模型, 要求进入全连接层之前, 最后一个卷积层输出的特征图像大小必须一致, 否则无法接入; 在卷积层固定的情况下, 进而要求输入的原始图片尺寸必须一致。R-CNN 中由于选择的候选区域尺度不一样, 因而先要将候选区域放缩到要求尺寸, 再进行卷积网络运算, R-CNN 主要的运算时间都消耗在 2 000 次的特征提取中。何凯明等人提出的 SPPnet^[30], 在最后一个卷积层后设计金字塔池化层, 通过金字塔池化层, 将特征图像固定到要求的尺寸。

SPPnet 同样只有在特征提取时用到卷积神经网络, 相比于 R-CNN, 它只做了一次卷积操作, 极大地节约了时间, 将单幅图像卷积网络测试的时间提升到了 0.5 s。SPPnet 优化了 R-CNN 时间开销的问题, 没有优化空间开销。

4.2.2 Fast-R-CNN

传统卷积神经网络最后的输出是属于什么类别的概率, 只能解决分类问题。为了实现目标的定位, R-CNN 引入了边框回归算法 (bounding box regression), 在 SVM 里输出可以确定目标位置的 4 个参数——目标左上角坐标点和长宽, 保证定位的实现^[21, 31-32]。而如果想解决 R-CNN 空间开销问题, 有必要将边框回归纳入卷积神经网络, 省略转存数据的步骤。

针对此问题, R-CNN 的提出者之一 Girshick 给出了改进方案, 即 Fast-R-CNN, Fast-R-CNN 提出了多任务损失函数 (multi-task loss), 在传统的损失函数后边加入目标定位的损失, 用来修正位置信息。其输出层同理变为两部分, 即分类层 (softmax) 和回归层 (bbox regressor)^[33], 如图 9 所示。




图9 Fast-R-CNN 网络结构

Fast-R-CNN 将边框回归直接加到 CNN 网络中训练, 完全代替 SVM, 实现了特征提取和分类定位的融合, 极大地提高了训练速度和检测速度。

4.2.3 Faster-R-CNN

Fast-R-CNN 用卷积神经网络同时完成了目标检测中的特征提取和分类, 但对于候选区域的选择仍然使用传统算法 selective search^[34], 该算法用时 2 s, 而后续的过程仅用 0.32 s, 这使得 Fast-R-CNN 并不能做到完全的实时检测。任少卿等人由此设计了 Faster-R-CNN 结构, 使用卷积神经网络直接产生候选区域。

Faster-R-CNN 在最后卷积层输出的特征图像上加入滑动窗口, 滑动窗口划过的位置, 以窗口中心为中心 (锚点), 做出不同尺寸的锚点框, 映射到原始图片, 成为候选区域。

Faster-R-CNN 其网络分为两部分: 第一部分用于候选区域的生成 (RPN 网络); 第二部分用于对候选区域的检测并识别其中的目标 (Fast-R-CNN 网络)^[28], 如图 10 所示。为了提高训练效率, 两个网络部分区域权值共享。在 VGG-16 模型上, 二者共用了 13 个卷积层, 采用交替训练 (alternating training) 实现卷积层特征共享。




图10 Faster-R-CNN 训练流程

Faster-R-CNN 用卷积神经网络完成了目标检测的所有工作, 完全实现了端到端的训练, 解决了 R-CNN 空间开销和时间开销问题, 并在 mAP 上取得提升。Faster-R-CNN 的不足主要有: 一是在候选区域选择上过分依赖锚点框, 而锚点框是人工设计、大小确定的, 实际目标在图片中的大小千姿百态, 在训练中发现边框回归收敛速度慢^[35]; 二是 RPN 网络也是由卷积网络训练得到, 与 Fast-R-CNN 部分特征共享, 导致 RPN 若出现错误, 后者难以修正, 在测试中主要表现为将背景区域错误划分为目标物体区域。

4.2.4 R-FCN

自 AlexNet 以来, CNN 网络在卷积层之后会接上若干个全连接层, 将卷积层产生的特征图映射成一个固定长度的特征向量。实际上, 完全可以将全连接层看作是对整个特征图的卷积, 即用卷积层代替全连接层, 这种网络被称为全卷积网络 (Fully Convolutional Networks, FCN)^[36-37]。如图 11 所示, 若上方的图片的全连接层看作是通过 4 096 个 6×6 的卷积核卷积得到的, 那么对于大小不同的下方的图, 同样的步骤得到的是一定尺寸的特征图像。




图 11 全卷积网络示意

全连接层由于将所有特征信息都展开到一维,丧失了对检测目标位置的敏感性^[38],目标检测不同于图像分类,需要精确的物体位置信息,这正是FCN网络所解决的问题。

Li 等人提出的R-FCN^[39]采用FCN网络结构,并用专门的卷积层构建位置敏感分数地图(position-sensitive score maps),在将全连接层变为一个卷积层同时,在该卷积层后生成若干敏感分数图,分别确定目标的左上区、左中区、左下区等9个位置,实现目标的精修。

R-FCN在数据集PASCAL VOC 2012的准确率达到82%,测试时每张图像耗时170 ms,是目前最好的目标检测网络。

表1对基于目标候选区域的目标检测模型做了对比。

4.3 基于回归方法的目标检测模型

Faster R-CNN和R-FCN实现了端到端的训练,基本实现了实时检测,但是由于同时要训练两个卷积网络,仍然存在训练参数过多,训练时间长,网络结构复杂的问题。究其原因,是因为基于目标候选区域的算法在本质上还是以传统的思路看待目标检测,采用严格的“三步走”解决问题。而卷积神经网络有自己独特的优势,完全可以简化流程——YOLO(You Only Look Once)^[29]仅使用一个神经网络完成目标检测。YOLO的原理如图12所示,将图片划分成若干区域,每个区域只负责预测至多一个目标,用边框回归法修正目标区域。




图 12 YOLO网络结构

YOLO 只有一个训练网络,大大加快了检测的速度。目前YOLO在单个TitanX上的测试速度达到每秒45 帧,完全可以用于实时检测,fast YOLO 采用更小的卷积神经网络,测试速度更是达到每秒155 帧,但准确率有所下降。

YOLO 目前同样存在很多问题,主要有:一是YOLO 定位误差大,定位误差指输出的位置框和人工标定的框偏差大于某阈值,被判定检测失败;二是小目标识别效果不好,YOLO 要求每个网格内最多定位一个物体,因而当物体在图像中的尺寸较小并距离很近时,如天空中的一群飞鸟,无法将所有物体检测出来;三是定位回归时只用到全图的信息,没有充分利用特征图像,导致使用相同的网络层数,其mAP 不如Faster-R-CNN。

针对YOLO对目标检测的不足,谷歌团队设计了SSD(Single Shot MultiBox Detector)模型^[40],它以VGG-16为基础,在VGG最后一个卷积层后加入额外的卷积层,大小逐层递减,在每个卷积层上做滑动窗口,在不同尺度的特征图下找锚点框。SSD在做回归时用到了Faster-R-CNN的锚点思想,使用全图各个位置的多尺度区域特征进行回归,提高了目标检测的精度。SSD模型在PASCALVOC上将mAP提升至74.3%,同时在TitanX测试速度达到每秒59帧。

SSD 仍然没有解决对多个紧邻的小目标的检测问题。基于回归方法在近年刚刚兴起,测试速度上远快于基于候选区域方法,但平均准确率均值不如后者,主要体现在没有候选区域下直接做位置回归难度很大,训

表1 基于目标候选区域的目标检测模型对比

方法	CNN工作任务	优点	缺点
R-CNN	特征提取	CNN提取的特征通用性强于传统算法	时间、空间开销大
SPPnet	特征提取	对一幅图只做一次卷积运算,训练、测试速度快	空间开销大
Fast-R-CNN	特征提取 分类定位	用CNN完成分类定位,节约特征存储空间	用其他算法做候选区域选择,不是严格意义的端到端训练
Faster-R-CNN	选择候选区域 特征提取 分类定位	完全使用CNN完成目标检测,端到端的训练	模型复杂,定位框不准确
R-FCN	选择候选区域 特征提取 分类定位	定位更加精细,准确度最高	模型复杂

表2 基于回归方法的目标检测模型对比

方法	输入图片尺寸	优点	缺点
YOLO	448×448	网络简单轻巧	小目标识别效果不好
Fast YOLO	448×448	网络简单, 训练、测试速度极快, 可以直接用到视频级的处理	准确度较低
SSD300	300×300	提高了定位准确度	模型收敛慢
SSD512	512×512	整合了各类方法优点, 准确度高	模型收敛慢, 测试速度慢

练中会出现目标边框大范围抖动、定位难以收敛等现象, 其理论还有很大的提升空间。

表2对基于回归方法的目标检测模型进行对比。

5 结束语

近年来, 卷积神经网络在计算机视觉领域发展迅猛, 屡次创造令人惊叹的成绩, 深度学习的方法通用性强, 可移植性强, 其应用更是拓展到各个领域。本文主要阐述了卷积神经网络的基本结构和在图像识别、目标检测领域的研究进展。总结来看, 卷积神经网络能在近年取得成功主要依靠三大支柱: 大数据、大模型、大计算。大量的人工标注数据使有监督训练成为可能, 更深更大的模型提高了网络的识别能力, 与GPU的结合和计算机硬件的迅速发展使大规模训练变得省时而有效。

但真正对卷积神经网络的研究才刚刚起步, 有很多方面尚需进一步的深入探讨:

(1) 小样本高效学习。卷积神经网络需要动辄百万级的训练样本, 卷积神经网络对百万级样本训练过程也极为漫长, 如何从小量的数据中生成良好的神经网络将是未来的研究方向。

(2) 网络结构的优化。目前的趋势是网络越深, 卷积神经网络的测试效果越好, 部分网络甚至深达上千层。随着网络的加深, 过拟合和网络退化问题显得更加严重; 模型的增大也使卷积神经网络在普通设备上的应用受到限制, 尤其是移动设备。相比于人和其他动物的视觉机理, 传输过程也不可能高达数百层。卷积神经网络需要优化结构设计, 寻找更高效的神元结构和单元。

(3) 数学理论的完善。卷积神经网络目前理论落后于实践, 许多模块缺乏完善的数学理论, 对于一个模型众多参数的选择, 更多的是依靠科研人员的经验而非理论。完备的数学解释是卷积神经网络未来发展不可避免的问题。

加拿大多伦多大学Hinton教授自2006年提出深度学习的概念至今仅有十余年, 却在诸多领域展现了惊人的潜力和能力。卷积神经网络目前是深度学习领域研究最多、发展最快的分支, 有充分的理由相信, 卷积神经网络未来有更广阔的研究前景和应用空间。

参考文献:

[1] Duffy K R, Hubel D H. Receptive field properties of neurons in the primary visual cortex under photopic and

scotopic lighting conditions[J]. Vision Research, 2007, 47(19): 2569-2574.

[2] Fukushima K, Miyake S, Ito T. Neocognitron: A neural network model for a mechanism of visual pattern recognition[J]. IEEE Transactions on Systems, Man, and Cybernetics, 1983(5): 826-834.

[3] LeCun Y, Boser B, Denker J S, et al. Backpropagation applied to handwritten zip code recognition[J]. Neural Computation, 1989, 1(4): 541-551.

[4] Hinton G E, Osindero S, Teh Y W. A fast learning algorithm for deep belief nets[J]. Neural Computation, 2006, 18(7): 1527-1554.

[5] Ciresan D C, Meier U, Masci J, et al. High-performance neural networks for visual object classification, Technical Report No. IDSIA-01-11[R]. 2011-01.

[6] Ciregan D, Meier U, Schmidhuber J. Multi-column deep neural networks for image classification[C]// Proceedings of IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2012), 2012: 3642-3649.

[7] Berg A, Deng J, Fei-Fei L. Large scale visual recognition challenge 2010[R/OL]. (2010)[2017-02-28]. <http://www.image-net.org/challenges>.

[8] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]// Advances in Neural Information Processing Systems, 2012: 1097-1105.

[9] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]// Proceedings of ICLR 2015, 2015.

[10] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 1-9.

[11] Deng J, Dong W, Socher R, et al. ImageNet: A large-scale hierarchical image database[C]// Proceedings of IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2009), 2009: 248-255.

[12] Krizhevsky A. Learning multiple layers of features from tiny images[D]. University of Toronto, 2009.

[13] LeCun Y, Huang F J, Bottou L. Learning methods for generic object recognition with invariance to pose and lighting[C]// Proceedings of the 2004 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR 2004), 2004.

[14] Fei-Fei L, Fergus R, Perona P. Learning generative visual

- models from few training examples: An incremental bayesian approach tested on 101 object categories[J]. Computer Vision and Image Understanding, 2007, 106(1): 59-70.
- [15] Russakovsky O, Deng J, Su H, et al. Imagenet large scale visual recognition challenge[J]. International Journal of Computer Vision, 2015, 115(3): 211-252.
- [16] Hinton G E, Srivastava N, Krizhevsky A, et al. Improving neural networks by preventing co-adaptation of feature detectors[J]. arXiv preprint arXiv:1207.0580, 2012.
- [17] Nair V, Hinton G E. Rectified linear units improve restricted Boltzmann machines[C]//Proceedings of the 27th International Conference on Machine Learning (ICML-10), 2010: 807-814.
- [18] Bengio Y, Simard P, Frasconi P. Learning long-term dependencies with gradient descent is difficult[J]. IEEE Transactions on Neural Networks, 1994, 5(2): 157-166.
- [19] Lin M, Chen Q, Yan S. Network in network[J]. arXiv preprint arXiv:1312.4400, 2013.
- [20] Pascanu R, Mikolov T, Bengio Y. On the difficulty of training recurrent neural networks[C]//Proceedings of the 30th International Conference on Machine Learning (ICML 2013), Atlanta, GA, USA, 16-21 June, 2013: 1310-1318.
- [21] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[J]. arXiv preprint arXiv:1502.03167, 2015.
- [22] Glorot X, Bengio Y. Understanding the difficulty of training deep feed forward neural networks[J]. Journal of Machine Learning Research, 2010, 9: 249-256.
- [23] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.
- [24] He K, Zhang X, Ren S, et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification[C]//Proceedings of the IEEE International Conference on Computer Vision, 2015: 1026-1034.
- [25] Carreira J, Agrawal P, Fragkiadaki K, et al. Human pose estimation with iterative error feedback[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 4733-4742.
- [26] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE Conference On Computer Vision and Pattern Recognition, 2014: 580-587.
- [27] Everingham M, Van Gool L, Williams C K I, et al. The PASCAL Visual Object Classes (VOC) challenge[J]. International Journal of Computer Vision, 2010, 88(2): 303-338.
- [28] Ren R S, He K, Faster R. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2016, 39(6): 1137-1149.
- [29] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 779-788.
- [30] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[C]//Proceedings of European Conference on Computer Vision, 2014: 346-361.
- [31] Felzenszwalb P F, Girshick R B, McAllester D, et al. Object detection with discriminatively trained part-based models[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 32(9): 1627-1645.
- [32] Erhan D, Szegedy C, Toshev A, et al. Scalable object detection using deep neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2014: 2147-2154.
- [33] Girshick R. Fast R-CNN[C]//Proceedings of the IEEE International Conference on Computer Vision, 2015: 1440-1448.
- [34] Uijlings J R R, Van De Sande K E A, Gevers T, et al. Selective search for object recognition[J]. International Journal of Computer Vision, 2013, 104(2): 154-171.
- [35] Szegedy C, Reed S, Erhan D, et al. Scalable, high-quality object detection[J]. arXiv preprint arXiv:1412.1441, 2014.
- [36] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 3431-3440.
- [37] Hariharan B, Arbeláez P, Girshick R, et al. Hypercolumns for object segmentation and fine-grained localization[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 447-456.
- [38] Eigen D, Puhrsch C, Fergus R. Depth map prediction from a single image using a multi-scale deep network[C]//Advances in Neural Information Processing Systems, 2014: 2366-2374.
- [39] Li Y, He K, Sun J. R-FCN: Object detection via region-based fully convolutional networks[C]//Advances in Neural Information Processing Systems, 2016: 379-387.
- [40] Liu W, Anguelov D, Erhan D, et al. SSD: Single shot multibox detector[C]//Proceedings of European Conference on Computer Vision, 2016: 21-37.