

多尺度卷积神经网络融合 Transformer 的 竹材缺陷识别方法

杨松, 张锐, 朱良宽

(东北林业大学计算机与控制工程学院, 哈尔滨 150040)

摘要:在竹材缺陷识别的研究中, 竹片形状、缺陷部位颜色深浅及裂纹大小差异都是制约模型识别准确率的关键。针对上述问题, 提出一种适用于中小数据集的多尺度卷积神经网络融合 Transformer 的竹材缺陷识别方法, 以更好地提高竹材缺陷识别的准确率。该方法在卷积神经网络的主干上进行改进, 从获取不同尺度语义信息的角度出发, 首先利用卷积神经网络在不同尺度的特征图上捕捉图像局部语义信息, 然后将不同尺度的语义特征映射为特征符号, 同时引入 Sinkhorn 分词器对不同阶段的卷积神经网络特征符号化以减少特征冗余, 再通过 Transformer 对特征符号之间的关系进行建模以学习图像全局语义信息。试验结果表明, 与 VGG16、ResNet50、DenseNet121、ViT 这 4 种深度学习模型相比, 基于多尺度卷积神经网络融合 Transformer 的方法能够更高效地提高竹材缺陷识别模型的性能, 在竹材缺陷图像数据集上的平均识别准确率达到 99.13%。该方法识别速度更快、精度更高, 且具有良好的鲁棒性, 为竹材缺陷的实时自动识别提供了新思路, 同时也验证了所提出方法的有效性。

关键词:竹材缺陷识别; 多尺度; 卷积神经网络; Transformer; Sinkhorn 分词器

中图分类号: S762; TP242

文献标志码: A

文章编号: 2096-1359(2024)05-0126-08

Bamboo defect recognition method based on multi-scale convolutional neural network fusion Transformer

YANG Song, ZHANG Rui, ZHU Liangkuan

(College of Computer and Control Engineering, Northeast Forestry University, Harbin 150040, China)

Abstract: In the research of bamboo defect recognition, the different shapes of bamboo slices, the different color shades of defect areas, and the size of cracks are key issues that influence the accuracy of model recognition. A multi-scale convolutional neural network fused with Transformer architecture was proposed for bamboo defect recognition, particularly suitable for small and medium-sized datasets, aiming at enhancing the accuracy of defect detection. This study improved the backbone of convolutional neural networks, by focusing on capturing semantic information at various scales. Firstly, convolutional neural networks were used to capture local semantic information of images on feature maps of different scales. Then, semantic features of different scales were mapped into feature symbols. At the same time, a Sinkhorn tokenizer was introduced to symbolize the features of convolutional neural networks at different stages to reduce feature redundancy. Finally, Transformer was used to model the relationship between feature symbols to learn global semantic information of images. A series of experiments were conducted to evaluate the performance of the proposed method. This study utilized a dataset comprising 6 360 images of bamboo defects categorized into four types. The dataset was split at a ratio of 8:2 for training and validation. During the training phase, an end-to-end training strategy was employed, optimizing model hyperparameters by minimizing the loss function. In the inference phase, the model was evaluated using the set of validation, and performance differences were compared between the proposed method and deep learning models including VGG16, ResNet50, DenseNet121 and ViT. The experimental results showed that the method based on multi-scale convolutional neural network fusion Transformer can more efficiently improve the performance of the bamboo defect recognition model compared with the four deep learning models, i.e., VGG16, ResNet50, DenseNet121 and ViT. The average recognition accuracy on the bamboo defect image dataset in this study reached 99.13%. Further results of comparative experiments revealed that the proposed model achieved an improvement in accuracy ranging from 0.16% to 7.46% compared to VGG16, ResNet50, DenseNet121 and ViT models. Additionally, it demonstrated advantages in metrics such as parameters, FLOPs and inference time. This method had faster recognition

收稿日期: 2023-10-27

修回日期: 2023-11-28

基金项目: 黑龙江博士后出站启动金; 中央高校基本科研业务费专项资金 (DL12BB10-11)。

作者简介: 杨松, 男, 讲师, 研究方向为智能优化算法。E-mail: yangsong@nefu.edu.cn

speed, higher accuracy, and good robustness, which provides a new idea for real-time automatic identification of bamboo defects, also verifies the effectiveness of the proposed method.

Keywords: bamboo defect recognition; multi-scale; convolutional neural network; Transformer; Sinkhorn tokenizer

中国是世界上竹资源最丰富的国家之一,有 40 多属 500 多种^[1]。竹片凉席是由竹块制作而成的,具有透气、不易卷曲、不粘汗等优良特性^[2]。然而,受生产环境、材料、加工工艺等多种因素的影响,竹材在生产过程中常出现断片、裂纹、形状大小差异等缺陷。因此,准确高效地对竹材表面缺陷进行自动识别至关重要。

随着深度学习技术的发展,卷积神经网络(convolutional neural network, CNN)通过引入局部连接、权重共享、池化等操作,无须进行人工选取,只要训练好参数即可得到特征分类^[3],现已广泛应用在缺陷检测识别领域。胡峻峰等^[2]将传统 CNN 模型与迁移学习方法相结合对竹片缺陷进行识别,识别准确率达到了 98.97%。李丹等^[4]改进了轻量级卷积 SqueezeNet 用于带钢的缺陷识别。张振华等^[5]提出了一种基于改进的多通道卷积神经网络的光学薄膜缺陷识别方法。解晨辉等^[6]提出了一种基于双循环结构生成对抗网络生成高质量木材缺陷图像,解决了数据样本不足的问题。此外,Jiang 等^[7]针对钢管焊缝缺陷识别问题,改进了池化策略和特征选择方法,增强了 CNN 的特征选择能力。上述研究表明,CNN 模型在缺陷检测识别领域已经展现出良好的性能和泛化能力,但受局部感受野的限制,CNN 通过卷积核只注意到图像的局部特征,不具备优异的全局表示能力。

近期,研究者尝试将 Transformer 直接用于图像分类任务^[8],提出的 ViT(vision transformer)模型成功学习到图像的全局表示,在大型数据集上的性能超过了 CNN 模型^[9]。Hu 等^[10]将预训练好的 ViT 模型迁移到竹片缺陷数据集上,并改进了 dropout 方法,提高了识别的准确度。除了使用纯视觉 Transformer 进行图像分类任务,还有一些研究者尝试构建 CNN 与 Transformer 融合模型,利用 CNN 捕捉图像的局部信息,利用 Transformer 捕捉图像全局信息,旨在充分结合 CNN 和 Transformer 的优点来提高分类性能。Bello 等^[11]利用自注意力代替部分卷积操作以增强图像分类性能;Feng 等^[12]在 ViT 中引入 VGG 网络中的多层全连接层,极大地提高了对带钢缺陷图像的特征提取能力;唐东林等^[13]和 Hu 等^[14]提出了一种基于融合浅层 CNN 和 Transformer 模型的缺陷识别方法,并引入了 SE(squeeze and excitation)模块对重要特征通道

重点关注,从而提高识别性能。

在竹材缺陷识别研究中,竹片形状、缺陷部位的颜色深浅及裂纹大小差异都是制约模型识别准确率的关键。针对上述问题,基于 CNN 融合 Transformer 的缺陷识别方法均采用注意力机制替换卷积操作,或在 CNN 后直接简单地跟随 Transformer 模块,这些方法更侧重于加强模型对图像语义信息的关注和提取,而对缺陷本身的空间分布特征有所忽略。本研究从获取不同尺度语义信息的角度出发,提出一种适用于中小数据集的多尺度 CNN 融合 Transformer 编码器的竹材缺陷识别方法,利用 CNN 捕捉图像的局部信息,同时引入 Sinkhorn 分词器对不同阶段的 CNN 特征符号化以减少特征冗余,再将 Transformer 编码器插入 CNN 主干特征提取网络的不同阶段以捕捉图像的全局信息。

1 多尺度 CNN 融合 Transformer 识别方法

1.1 局部特征提取模块

模型局部特征提取部分主要基于 ResNet-50 网络,由于该网络中引入了残差结构,可以很好地解决深层 CNN 模型复杂度高、在中小数据集上难以训练的问题^[15]。ResNet 残差结构如图 1 所示^[16],将输入 x 与经过堆叠权重层得到的 $F(x)$ 进行跨层连接,得到输出 $H(x) = F(x) + x$,其中, $F(x) = H(x) - x$ 即为残差。




图 1 残差结构示意图^[16]

Fig. 1 Schematic diagram of residual block

局部特征提取模块结构如图 2 所示,预处理阶段从输入图像或其水平翻转的图像中随机采样并进行标准化处理,然后紧跟网络的 5 个卷积块 Conv 1~5,其由卷积层 Conv、最大池化层 MaxPool、批归一化层(batch normalization, BN)和激活层 ReLU 激活函数组成。




图 2 局部特征提取模块
Fig. 2 Local feature extraction module

1.2 全局特征提取模块

由于 CNN 模型通过卷积核只能对图像的局部相邻特征进行建模,但局部特征容易忽略图像不同区域之间的语义关联性,从而导致无法学习图像的全局信息,所以本研究在局部特征提取网络后融合 Transformer,将局部特征提取模块得到的特征图 $S_i \in R^{C \times H \times W}$ (C, H, W 分别表示特征图的通道数、高、宽) 采用 D 个步幅和大小都为 P 的卷积核进行卷积操作并展平为二维序列,产生个数为 N 的特征符号 $T_{in} \in R^{D \times N}$,这不同于 ViT 直接从输入图像提取特征符号,仅在单一尺度上处理图像会降低网络对不同大小缺陷特征的识别能力。 T_{in} 再额外嵌入一个与特征图符号特征维度相同的可学习变量 x_{class} ,可用于学习对象的全局特征表示。此外,为了将特征图空间排序编码到特征符号中,添加一个可学习的位置编码信息 $E_{pos} \in R^{D \times (N+1)}$,最终得到的特征符号如下:

$$Z_0 = [x_{class} \parallel T_{in}] + E_{pos} \tag{1}$$

式中, $\parallel$ 表示拼接。

Transformer 编码器包含 2 个子层:第 1 个子层由 LayerNorm 层和多头自注意力层 (multi-head self attention layer, MHSA) 构成,第 2 个子层由 LayerNorm 层和多层感知机 (multi-layer perceptron, MLP) 构成,且每个子层前后都添加了正则化和残差连接以避免梯度消失和网络退化,如图 3 所示。




图 3 Transformer 编码器结构
Fig. 3 The structure of Transformer encoder

1.3 Sinkhorn 分词器

传统的视觉 Transformer 基于非重叠图像块对原始图像进行符号化生成特征符号,这样的方法没有考虑到对图像中相似的图像块进行编码而产生的特征冗余,因此导致在生成的特征符号中不成比例地表示这些特征^[17],对这些冗余特征相互关系的学习也会加大网络的计算复杂度和推理成本。针对上述问题,本研究引入 Sinkhorn 分词器对从局部特征提取模块不同尺度特征图上提取的特征符号 T_{in} 进行符号化处理,以减少由于多尺度特征融合以及对相似特征编码而产生的特征冗余,其原理结构如图 4 所示^[17]。该方法首先利用余弦相似度来衡量输入的 N 个特征符号 T_{in} 和一组 K 个聚类中心 $C \in R^{D \times K}$ 之间的相似性以减少符号数量,聚类中心从 D 维的正态分布初始化,并基于相似性分数 V 计算软分配矩阵 Q ,使特征符号和聚类中心之间的相似性最大化:

$$\max_{Q \in \mathcal{Q}} \text{Tr}(Q^T V) + \epsilon H(Q) \tag{2}$$

式中: $V = C^T T_{in} \in R^{K \times N}$; $Q \in R^{K \times N}$; H 是矩阵熵函数; ϵ 控制其权重大小从而控制分配分数的平滑度。本研究设置聚类中心数 $K = 64, D = 512$ 。

式(2) 的解可以表示如下:

$$Q^* = \text{diag}(\alpha) \exp\left(\frac{V}{\epsilon}\right) \text{diag}(\beta) \tag{3}$$

式中, α 和 β 是通过 t_{sk} 次迭代 Sinkhorn-Knopp 算法^[18]得到的 2 个重整化向量。使用 Q^{*T} 将输入的特征符号聚类为较小的符号集合 T_{out} :

$$T_{out} = T_{in} Q^{*T} \tag{4}$$

1.4 模型整体架构

本研究所设计的缺陷识别模型以 ResNet-50 网络为基础,引入多尺度方法和 Transformer 编码器。改进得到的多尺度 CNN 融合 Transformer 模型整体框架如图 5 所示。由图 5 可知,输入图像经预处理后,通过特征提取主干网络 ResNet50 学习图像的局部特征。由于周期性的池化操作,卷积神经网络中具有一组自然尺度。每个尺度的代表性特征图被定义为每个池化操作之前的最后一个特征




图 4 Sinkhorn 分词器结构^[17]

Fig. 4 The structure of Sinkhorn tokenizer

图,并用 S_i 表示第 i 个尺度。按照 ResNet 的模型架构将模型局部特征提取模块分为 5 个阶段,根据每个阶段产生的不同尺寸特征图将其定义为具有 5 个自然尺度:Stem 以及 Scale 1~4,并用编号 1~5 表示。在每个尺度的特征图 S_i 上,每个特征符号 T_{in}^i 都先被线性投影到一个 D 维空间中,随后被 Sinkhorn 分词器符号化,输出表示为 T_{out}^i ;将每个尺度的特征符号拼接后输入 L 层 Transformer 编码器模块,利用多头自注意力机制对全局特征建模,生成多尺度特征:

$$Z_L^i = \varphi^i(\parallel_j^i T_{out}^i + T_{out}^i) \tag{5}$$

式中: j 表示特征符号化初始的尺度; φ 表示 Transformer 编码器。

例拆分数据集,且所有图像都根据其缺陷类别分配了唯一编号,可以通过编号快速准确地识别图像。拆分后的竹片缺陷种类、样本数量如表 1 所示。可以发现,d 类的样本数目相对其他类别较少,这可能导致训练模型时对于不同类别产生偏差,所以在预处理阶段对数据集图像进行数据增强以均衡图像分布。具体方式有随机裁剪、水平翻转以及高斯噪声等,并将每张图片裁剪为 224×224 大小传入模型训练。原始图片和数据增强以后的图片见图 6。其中,半片材和废片材的图像如图 6a₁、a₂所示,半片材只有正常竹材一半大小,废片材是与正常竹片形状差异较大的竹材;花片材和烂头材的图像如图 6a₃、a₄所示,花片材是缺陷部位颜色深浅不一的竹材,烂头材表面存在裂纹且缺陷部位面积存在差异。

表 1 竹材缺陷图像数据集划分

Table 1 Division of bamboo defect dataset

类别编号	缺陷类别	训练集	测试集
a	半片材	1 371	342
b	废片材	1 382	345
c	花片材	1 375	343
d	烂头材	962	240




图 5 多尺度 CNN 融合 Transformer 模型结构
Fig. 5 The structure of multi-scale CNN fusion Transformer

2 试验设置

2.1 试验数据集与预处理

本研究采用相同的拍摄设备保持同样的拍摄距离和拍摄角度,采集了 4 类共 6 360 张竹片图像,按照 8:2(80%为训练集、20%为验证集)的比




图 6 竹材缺陷图像数据集样本
Fig. 6 The samples of bamboo defect dataset

2.2 试验环境与参数设置

本研究所采用的试验平台为 PyCharm,深度学习框架为 Pytorch, CPU 为 Intel (R) Core (TM) i5-12500H, GPU 为 NVIDIA GeForce RTX 3060 (6 GB)。试验环境为 python 3.8, CUDA11.6。本研究的训练策略和超参数设置是在大量试验中确定的,详细的参数设置如表 2 所示。

表 2 试验参数设置
Table 2 Experiment parameters setting

参数名称	参数值
image size	224
epochs	60
batch size	32
learning rate (LR)	0.000 5
weight decay	0.000 05
LR scheduler	Cosine Annealing
optimizer	Adam
loss function	cross-entropy

2.3 评价指标

本研究采用准确率 (accuracy)、精确率 (precision, 式中记为 P)、召回率 (recall, 式中记为 R) 和 F_1 分数作为缺陷识别模型的评价指标,使用参数量和浮点运算量 (FLOPs) 来分析模型复杂度,并使用单张图片推理时间 (inference time) 和刷新率来分析缺陷识别的实时性。试验的最终结果取多次试验的平均值,以更加客观地反映模型的分类性能。部分评价指标具体计算公式为:

$$P = \frac{T_p}{T_p + F_p} \tag{6}$$

$$R = \frac{T_p}{T_p + F_N} \tag{7}$$

$$F_1 = \frac{2 \times P \times R}{P + R} \tag{8}$$

式中: T_p 是正样本被识别为正样本的数量; F_p 是正样本被识别为负样本的数量; F_N 是负样本被识别为正样本的数量。

3 结果与分析

试验中训练集负责进行参数学习以拟合模型,测试集用以对模型性能进行评估,不参与训练与参数学习,因此以下试验均采用测试集的试验结果作为模型评价指标。

3.1 缺陷分类试验

为验证本研究所改进的竹材缺陷分类模型性能,在竹材缺陷数据集上进行试验,模型准确率和损失变化如图 7 所示。由于训练初期学习率相对

较大,导致准确率和损失有一定波动,但总体准确率呈上升趋势并快速收敛,在迭代至第 50 个 epoch 时模型接近收敛。经过多次独立试验对准确率取平均值,得到本研究新提出的多尺度 CNN 融合 Transformer 结构对竹片缺陷的分类准确率为 99.13%。




图 7 竹材缺陷识别性能曲线
Fig. 7 The performance curves of bamboo defect recognition

使用混淆矩阵可以更直观地展示模型对各类别竹片缺陷的具体识别情况,如图 8 所示。其中,横坐标代表缺陷的真实类别,每行总数代表该类别的真实数据;纵坐标代表缺陷的预测类别,每列总数代表该类别的预测数据;对角线代表真实类别与预测类别相同,其值为分类正确的结果总和。从图 8 中可以看出,模型整体的识别准确率较高,但由于各类图片之间纹理、缺陷、形状等特征比较类似,依旧存在识别混淆现象,其中识别准确率最低的是 a 类,分别有 2 张被识别为 c 类和 d 类。




图 8 竹材缺陷识别混淆矩阵
Fig. 8 Confusion matrix of bamboo defect recognition

3.2 对比试验

为了验证本研究方法在竹片缺陷数据集上的综合性能,分别将本方法与文献[2]中的基于迁移学习 (TL) 改进的 CNN 竹材缺陷识别方法

VGG16-TL、ResNet50-TL、DenseNet121-TL 以及文献[10]中改进的 Transformer 模型 ViT-TL 进行对比试验。各模型在测试集上的具体性能对比结果如表 3 所示。

表 3 模型综合指标对比
Table 3 Comparison of model comprehensive indicators

模型	准确率/%	精确率/%	召回率/%	F_1 分数	计算量/ GB	参数量/ MB	推理时间/ ms	刷新率/ (帧·s ⁻¹)
VGG16-TL ^[2]	91.98	91.89	91.98	0.920	15.47	138.36	9.20	108
ResNet50-TL ^[2]	91.67	91.25	92.11	0.917	4.13	25.56	8.46	118
DenseNet121-TL ^[2]	98.97	98.79	98.91	0.987	2.83	7.90	17.03	58
ViT-TL ^[10]	95.39	95.11	95.38	0.954	16.86	86.42	8.58	116
本研究方法	99.13	99.10	99.04	0.991	5.11	31.39	9.54	104

试验结果表明,本研究方法与 VGG16-TL、ResNet50-TL、DenseNet121-TL 以及 ViT-TL 相比,准确率分别提高 7.15,7.46,0.16,3.74 个百分点,精确率分别提高 7.21,7.85,0.31,3.99 个百分点,召回率分别提高 7.06,6.93,0.13,3.66 个百分点。其中,本研究方法的准确率、精确率、召回率、 F_1 分数均达到 99% 以上,说明该模型针对竹材缺陷识别的有效性较高。虽然 Densenet121-TL 的准确率与本研究相近,且计算量和参数量更少,但本研究模型推理时间更短,刷新率能够满足实时检测的要求;同样的,相比 ResNet50-TL,本研究方法在保证

高效率的同时,对图像的全局特征建模能力是其不具有的,因而在准确率上表现更优。

各模型的分类准确率与损失 (Loss) 曲线见图 9,从图 9 中可以看出,由于 ViT-TL 直接学习图像的全局信息,且对训练数据量的要求较高,所以在本研究数据集上学习比较困难,迭代曲线波动较大,网络收敛较慢。相比其他 4 种基于迁移学习策略改进的模型来说,本研究所提出的方法虽然在试验初期曲线波动较大,但能够快速收敛并且达到最高的识别准确率,体现了本研究所改进的多尺度 CNN 融合 Transformer 方法的性能。




图 9 竹材缺陷识别性能对比曲线
Fig. 9 The performance comparison curves of bamboo defect recognition

3.3 消融试验

为了验证本研究提出的多尺度 CNN 融合 Transformer 模型以及各个模块的有效性,设计了不同方法的消融试验,所有试验都是在竹片缺陷图像数据集下展开的。

3.3.1 多尺度 CNN 融合 Transformer 的性能分析

为了验证多尺度方法和 Transformer 对模型性能的影响,将 CNN 模型、CNN-Transformer 模型和本研究提出的引入多尺度 CNN-Transformer 模型进行对比试验,多尺度方法均在 CNN 主干网络 ResNet50 的最后 3 个阶段进行试验训练。试验结

果表明,CNN 模型、CNN-Transformer 模型和引入多尺度 CNN-Transformer 模型的准确率分别为 98.89%,98.97% 和 99.13%,可以看出,Transformer 和多尺度方法都能够有效改进模型的分类性能,在利用 CNN 进行局部特征提取的基础上,利用 Transformer 能够实现对图像全局特征的建模,引入多尺度方法能在 CNN 特征图层面做进一步的特征提取,相较于经典的单尺度 CNN-Transformer 架构,性能有一定的提升。

3.3.2 Sinkhorn 分词器的性能分析

本研究模型在 Sinkhorn 与传统的视觉

Transformer 基于非重叠图像块对原始图像进行符号化的 2 种分词器下的分类准确率、计算量以及吞吐量(throughput)对比结果见表 4。由表 4 可知, Sinkhorn 分词器相较于 Patch 分词器在分类准确率上实现了 0.55% 的性能提升, 而且在模型计算量和吞吐量上都有明显的优势。试验结果表明, Sinkhorn 分词器可以很好地帮助模型解决特征冗余的问题, 并且提高推理效率, 从而提高模型的性能。

表 4 分词器性能分析
Table 4 Performance analysis of tokenizers

分词器	准确率/%	计算量/GB	吞吐量/(img·s ⁻¹)
Patch	98.58	7.08	260.40
Sinkhorn	99.13	5.11	340.95

3.3.3 多尺度方法的性能分析

比较了局部特征提取模块中使用 CNN 不同尺度特征图时的网络性能, 即通过对 ResNet50 网络除 Stem 外所有阶段特征图的不同尺度子集进行比较, 验证多尺度方法对模型性能的影响。试验结果如表 5 所示, 表中第一列为不同尺度子集的设置。可以看出, 多尺度的方法相对于单尺度 CNN-Transformer 架构仅有少量计算量和参数量的增加, 却带来了一定的性能提升, 但是使用过多的尺度会降低一些性能。其中, 尺度子集 {3, 4, 5} 实现了最高的缺陷识别准确率, 证明了多尺度的方法在竹片缺陷数据集上可以充分发挥性能。

表 5 多尺度方法性能分析
Table 5 Performance analysis of multi-scale method

尺度	准确率/%	计算量/GB	参数量/MB
{5}	98.44	4.59	30.87
{4, 5}	99.05	5.01	31.03
{3, 4, 5}	99.13	5.11	31.39
{2, 3, 4, 5}	98.97	6.54	31.78

3.3.4 不同 Transformer 深度下的模型性能分析

通过设置全局特征提取模块 Transformer 编码器的层数 L 分别为 1, 2, 3, 4 时, 得到 4 个不同的模型进行试验, 试验结果如表 6 所示。

表 6 Transformer 深度性能分析
Table 6 Performance analysis of the depth of Transformer

L	准确率/%	计算量/GB	参数量/MB
1	98.97	4.70	28.24
2	99.13	5.11	31.39
3	98.42	5.51	34.54
4	98.35	5.92	37.70

从表 6 中的结果来看, 随着 Transformer 深度

从 1 增加到 4, 模型的性能并未随着深度的增加而提高, 深度太浅或者太深都会导致模型缺陷识别准确率下降, 当 Transformer 深度为 2 时模型准确率达到最高, 之后随着深度增加, 模型性能开始下降。

4 结 论

本研究提出一种多尺度 CNN 融合 Transformer 的竹材缺陷识别方法。首先, 使用 CNN 提取图像的局部语义特征; 其次, 将得到的不同尺度局部特征映射为特征符号, 并通过 Sinkhorn 分词器减少特征符号的冗余; 然后融合基于注意力机制的 Transformer 对特征符号之间的关系进行建模以提取图像的全局特征; 最后将获得的缺陷特征输出进行分类。研究结果表明, 本研究提出的方法在准确率、计算量、参数量、推理时间等重要评价指标上都显著优于其他主流的图像分类模型, 多尺度 CNN 融合 Transformer 的策略显著提升了模型的性能, 具备在生产环境应用的潜力, 对实现竹片缺陷的在线高效率、高精度识别具有现实意义。在处理缺陷、纹理和形状特征较为相似的竹片图像时, 仍会出现一定程度的识别混淆, 因此, 未来工作可以考虑结合更多的先验知识或使用其他的优化技术以进一步提高识别性能。

参考文献(References):

[1] 王登举, 李智勇, 樊宝敏. 中国竹产业发展中的投融资及税费问题[J]. 世界竹藤通讯, 2006, 4(1): 31-33. DOI: 10.3969/j.issn.1672-0431.2006.01.009.
WANG D J, LI Z Y, FAN B M. Investment and taxation of bamboo industry development in China[J]. World Bamboo and Rattan, 2006, 4(1): 31-33.

[2] 胡峻峰, 张志超, 赵亚凤, 等. 基于迁移学习的竹片缺陷识别[J]. 西北林学院学报, 2021, 36(5): 190-196. DOI: 10.3969/j.issn.1001-7461.2021.05.29.
HU J F, ZHANG Z C, ZHAO Y F, et al. Defect recognition of bamboo sheets based on transfer learning[J]. Journal of Northwest Forestry University, 2021, 36(5): 190-196.

[3] 徐姗姗, 吕净妍, 陈芳媛. 深度卷积神经网络的遥感植被检测方法[J]. 南京林业大学学报(自然科学版), 2022, 46(4): 185-193. DOI: 10.12302/j.issn.1000-2006.202009059.
XU S S, LYU J Y, CHEN F Y. Remote sensing vegetation detection method based on the deep convolutional neural network[J]. Journal of Nanjing Forestry University (Natural Sciences Edition), 2022, 46(4): 185-193.

[4] 李丹, 王慢慢, 刘俊德, 等. 基于轻量级卷积神经网络的带钢表面缺陷识别[J]. 仪器仪表学报, 2022, 43(3): 240-248. DOI: 10.19650/j.cnki.cjsi.J2108652.
LI D, WANG M M, LIU J D, et al. Steel surface defect recognition based on a lightweight convolutional neural network[J]. Chinese Journal of Scientific Instrument, 2022, 43(3): 240-248.

[5] 张振华, 陆金桂, 李浩然. 基于改进的卷积神经网络光学薄膜缺陷识别[J]. 计算机应用与软件, 2021, 38(4): 197-203. DOI: 10.3969/j.issn.1000-386x.2021.04.032.

ZHANG Z H, LU J G, LI H R. Defect identification of optical film based on improved convolutional neural network [J]. Computer Applications and Software, 2021, 38(4): 197-203.

[6] 解晨辉, 杨博凯, 李荣荣. 基于双循环生成对抗网络和 Dense-Net 的木材缺陷检测方法[J]. 林业工程学报, 2023, 8(4): 129-136. DOI: 10.13360/j.issn.2096-1359.202212008.

XIE C H, YANG B K, LI R R. Wood defect detection method based on double least generative adversarial networks and Dense-Net[J]. Journal of Forestry Engineering, 2023, 8(4): 129-136.

[7] JIANG H Q, HU Q H, ZHI Z L, et al. Convolution neural network model with improved pooling strategy and feature selection for weld defect recognition[J]. Welding in the World, 2021, 65(4): 731-744. DOI: 10.1007/s40194-020-01027-6.

[8] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[EB/OL]. (2021-06-03) [2023-10-27]. <http://arxiv.org/abs/1706.03762>.

[9] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: transformers for image recognition at scale[EB/OL]. (2021-06-03) [2023-10-27]. <http://arxiv.org/abs/2010.11929>.

[10] HU J F, YU X, ZHAO Y F. Bamboo defect classification based on improved transformer network[J]. Wood Research, 2022, 67(3): 501-510. DOI: 10.37763/wr.1336-4561/67.3.501510.

[11] BELLO I, ZOPH B, LE Q, et al. Attention augmented convolutional networks [C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South). IEEE, 2019: 3285-3294. DOI: 10.1109/ICCV.2019.00338.

[12] FENG X L, GAO X W, LUO L. An improved Vision Transformer-based method for classifying surface defects in hot-rolled strip steel [J]. Journal of Physics: Conference Series, 2021, 2082(1): 012016. DOI: 10.1088/1742-6596/2082/1/012016.

[13] 唐东林, 杨洲, 程衡, 等. 浅层卷积神经网络融合 Transformer 的金属缺陷图像识别方法[J]. 中国机械工程, 2022, 33(19): 2298-2305. DOI: 10.3969/j.issn.1004-132X.2022.19.003.

TANG D L, YANG Z, CHENG H, et al. Metal defect image recognition method based on shallow CNN fusion transformer[J]. China Mechanical Engineering, 2022, 33(19): 2298-2305.

[14] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT, USA. IEEE, 2018: 7132-7141. DOI: 10.1109/CVPR.2018.00745.

[15] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[EB/OL]. (2015-04-10) [2023-10-27]. <http://arxiv.org/abs/1409.1556>.

[16] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, NV, USA. IEEE, 2016: 770-778. DOI: 10.1109/CVPR.2016.90.

[17] HAURUM J B, MADADI M, ESCALERA S, et al. Multi-scale hybrid vision transformer and Sinkhorn tokenizer for sewer defect classification [J]. Automation in Construction, 2022, 144: 104614. DOI: 10.1016/j.autcon.2022.104614.

[18] CUTURI M. Sinkhorn distances: lightspeed computation of optimal transportation distances [EB/OL]. (2013-06-04) [2023-10-27]. <http://arxiv.org/abs/1306.0895>.

(责任编辑 莫弦丰)

《林业工程学报》2025 年征订启事

《林业工程学报》(CN 32-1862/S)是由南京林业大学主办、国内外公开发行的全国性林业工程类学术期刊,2016 年创刊,其办刊宗旨为:以精品化、国际化为导向,重点报道木材科学与技术、林产化学加工工程、森林工程、家具设计与工程、装备与信息化等方面的科研成果和最新进展,大力促进林业工程学科的科研创新和学术交流,培养高层次林业工程人才,积极推动我国林业工程学科向更高水平发展,努力把本刊办成林业工程研究成果展示的窗口与学术交流的平台。

《林业工程学报》为 Scopus 数据库收录期刊、中文核心期刊、CSCD(中国科学引文数据库)和 SCD(科学引文数据库)收录期刊、中国科技核心期刊、RCCSE 中国核心学术期刊。《林业工程学报》将依托南京林业大学国家一流学科“林业工程”的优势,广泛联合国内外林业工程学科的力量,力争在较短时间内办出国内一流并具有国际水准的林业工程学术期刊。

《林业工程学报》主要栏目有:专论综述、木材科学与低碳利用、林产化工与绿色利用、生物质材料与能源、林业装备与智能化、森林工程与土建、家具工程与智能制造等。

本刊适合于从事林业工程科研、教学和技术开发人员阅读参考,对林业院校相关学科的师生具有较强指导作用。欢迎各有关单位和读者通过全国各地邮局订阅,也可通过电话或电子邮箱向本刊编辑部直接订阅。

本刊为双月刊,大 16K,192 页,逢单月 25 日出版,公开发行,邮局发行代号 28-103。

单价:50 元/册,全年 300 元。

本刊编辑部电话:025-85427227,85427298

<http://lygxcb.njfu.edu.cn> E-mail:lygxcb@vip.163.com

地址:南京市龙蟠路 159 号南京林业大学内 邮编:210037

万方数据