





第4章

Yolov3

目标检测

算法原理

Yolov3目标检测的背景



Joseph Redmon
@pjreddie

回复 @pjreddie


I stopped doing CV research because I saw the impact my work was having. I loved the work but the military applications and privacy concerns eventually became impossible to ignore.

YOLOv3是YOLO系列的第三个版本，于2018年由Joseph Redmon发布。YOLOv3相对于前两个版本有一些显著的改进，包括更高的准确性和更好的泛化能力。但是在2020年，Joseph Redmon宣布：我现在已经停止了计算机视觉研究，因为我看到了自己工作造成的影响。我热爱自己的作品，但我已经无法忽视它在军事领域的应用以及给个人隐私带来的风险。




Yolov3模型结构图






Yolov2网络模型结构:




Yolov3网络模型结构:




Yolov3分类模型具体参数








Yolov3图像金字塔(FPN)



Yolov3检测头



Yolov3检测头




$$b_x = \sigma(t_x) + c_x$$

$$b_y = \sigma(t_y) + c_y$$

$$b_w = p_w e^{t_w}$$

$$b_h = p_h e^{t_h}$$

Yolov3检测模型具体参数




Yolov3中的正负样本

1、预测框一共分为三种情况:正例(positive)、负例(negative)、忽略样例(ignore)。

2、正例:任取一个标注框,与全部计算IOU, IOU最大的预测框,即为正例。并且一个预测框,只能分配给一个标注框。例如第一个标注框已经匹配了一个正例检测框,那么下一个标注框,就在余下的检测框中,寻找IOU最大的检测框作为正例。标注框的先后顺序可忽略。正例产生置信度loss、检测框loss、类别loss。预测框坐标对应的标注框标签;类别标签对应类别为1,其余为0;置信度标签为1。

3、忽略样例:正例除外,与任意一个ground truth的IOU大于阈值(论文中使用0.5),则为忽略样例。忽略样例不产生任何loss。

4、负例:正例除外(与ground truth计算后IOU最大的检测框,但是IOU小于阈值,仍为正例)与全部ground truth的IOU都小于阈值(0.5),则为负例。负例只有置信度产生loss、置信度标签为0。



Yolov3的损失函数

Yolov3损失函数公式：

$$\begin{aligned} loss = & \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B 1_{i,j}^{\text{obj}} \cdot \left[\left(b_x - b_x \right)^2 + \left(b_y - b_y \right)^2 + \left(b_w - b_w \right)^2 + \left(b_h - b_h \right)^2 \right] (2 - w_i \times h_i) \\ & + \sum_{i=0}^{S^2} \sum_{j=0}^B 1_{i,j}^{\text{obj}} \cdot \left[-\log(p_c) + \sum_{i=1}^n BCE(\hat{c}_i, c_i) \right] \\ & + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B 1_{i,j}^{\text{noobj}} \cdot \left[-\log(1 - p_c) \right] \end{aligned}$$

Yolov3的损失函数

Yolov3损失函数公式：

$$\lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B 1_{i,j}^{\text{obj}} \cdot \left[(b_x - b_x)^2 + (b_y - b_y)^2 + (b_w - b_w)^2 + (b_h - b_h)^2 \right] (2 - w_i \times h_i)$$


正样本位置损失

小框损失惩罚项，总结就是让小框的损失系数变大。其主要原因是，如果没有惩罚项的话，大框的损失会很轻易大于小框，因此当框越大，这个惩罚项越小，框越小，这个惩罚项越大。

Yolov3的损失函数

Yolov3损失函数公式：

$$\sum_{i=0}^{S^2} \sum_{j=0}^B 1_{i,j}^{obj} \cdot \left[-\log(p_c) + \sum_{i=1}^n BCE(\hat{c}_i, c_i) \right] \quad \text{正样本置信度损失与类别损失}$$
$$+ \lambda_{noobj} \sum_{i=0}^{S^2} \sum_{j=0}^B 1_{i,j}^{noobj} \cdot \left[-\log(1 - p_c) \right] \quad \text{负样本置信度损失}$$



关于置信度损失：

这里要强调一点，前面yolov1和yolov2置信度的标签值利用的是预测框和标注框之间的交并比。这就导致无论怎么学习预测框和标注框的最大值为0.7。也就是置信度最大输出值为0.7，很显然这个值是不合理的，因此在该项损失中利用0和1作为置信度的标签，正样本中置信度标签为1，负样本中标签为0。因此对应损失函数中，正样本置信度为1时，负样本为0时，对应的置信度损失为0。

关于分类损失：

在前面的yolov1和yolov2最后输出利用softmax来进行概率预测，该种激活函数计算概率有一个特点就是所有类别的概率相加等于1，因此只能进行单一分类预测，而在yolov3中将softmax修改成sigmoid函数，对不同类别进行概率预测，这样就可以进行概率预测，例如有些数据将人和女人分成两类，这样就可以进行多标签类别的分类预测。

Yolov3总结

优势:

- 1、多尺度检测：YOLOv3在三个不同的尺度上进行检测，提高了模型对于不同大小物体的识别能力。
- 2、在类别预测方面，YOLOv3采用了逻辑回归而非softmax，从而可以更好地处理多标签场景。
- 3、更多的Anchor Boxes：YOLOv3使用了多达9个锚框（分布在三个不同的尺度上），相比YOLOv2更能准确地适应不同形状和大小的目标。
- 4、更大的模型和更深的架构：YOLOv3使用了Darknet-53，一个比YOLOv2的Darknet-19更大、更深的网络架构，以获得更高的准确性。
- 5、新的损失函数：YOLOv3采用了一个新的损失函数，更加注重目标的定位和分类，使模型在多方面都得到了改进。

缺点:

- 1、小目标检测仍有局限性：尽管YOLOv3通过多尺度检测做了一定程度的改进，但对于小目标的检测准确性相对仍然较低
- 2、高置信度的错误检测：YOLOv3可能会生成一些高置信度的错误检测，尤其是在目标密集或重叠的场景中

